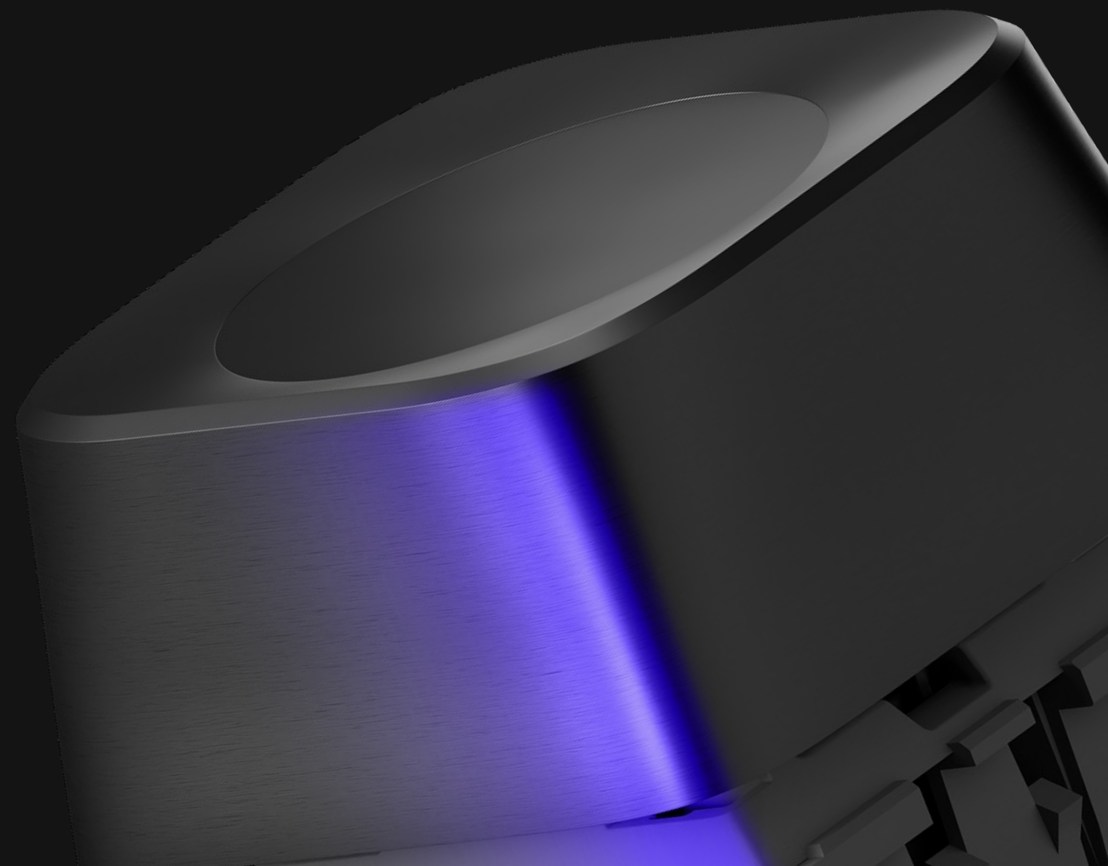
ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

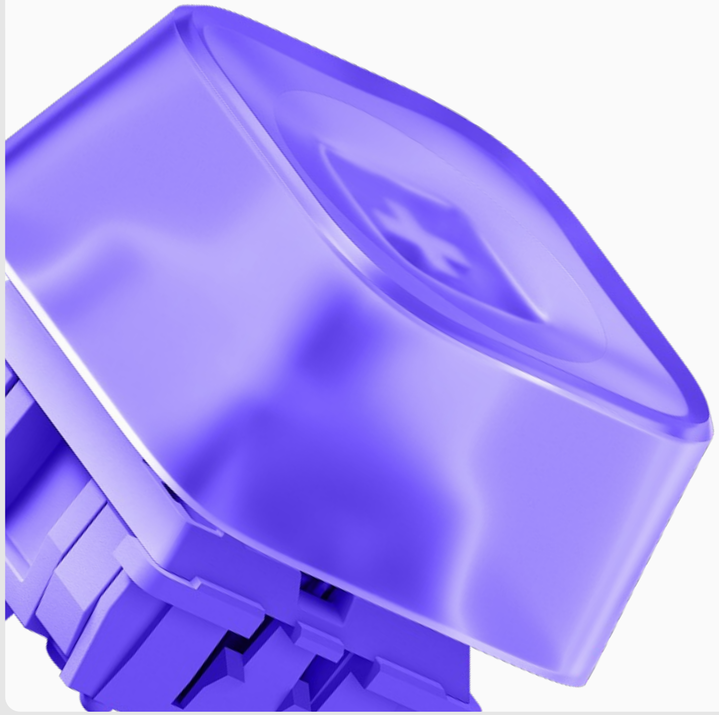
Интро в курс ML



Машинное обучение

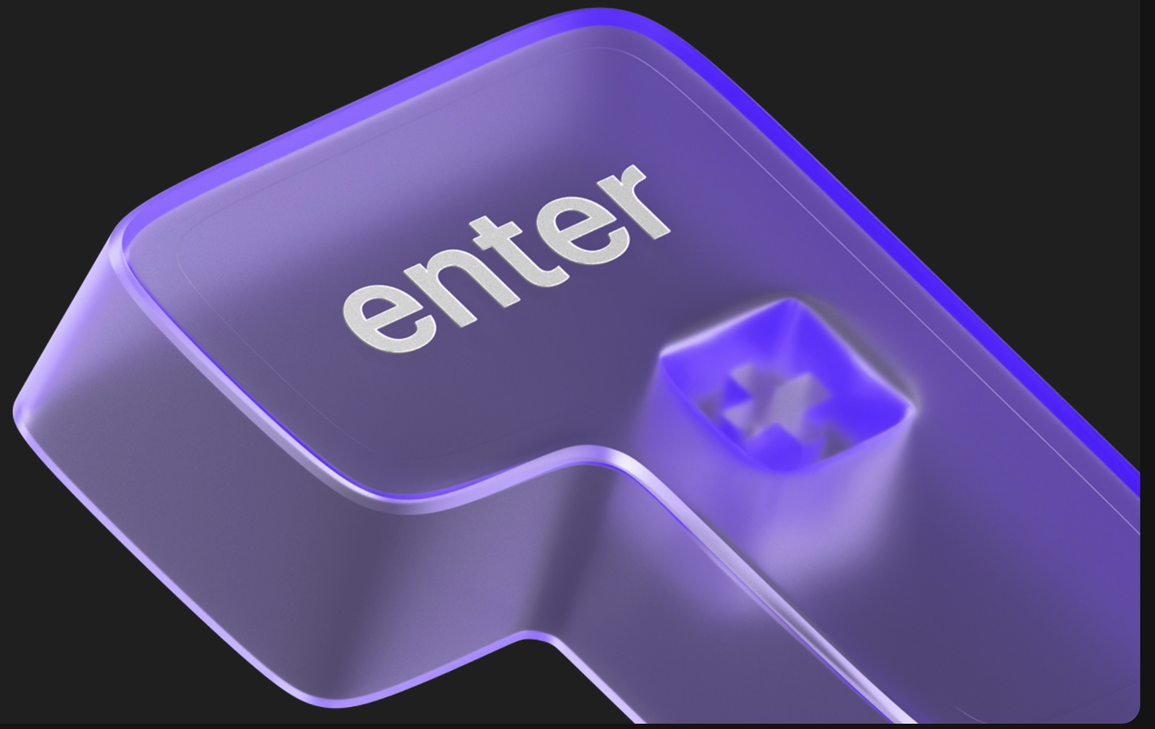
00

План лекции

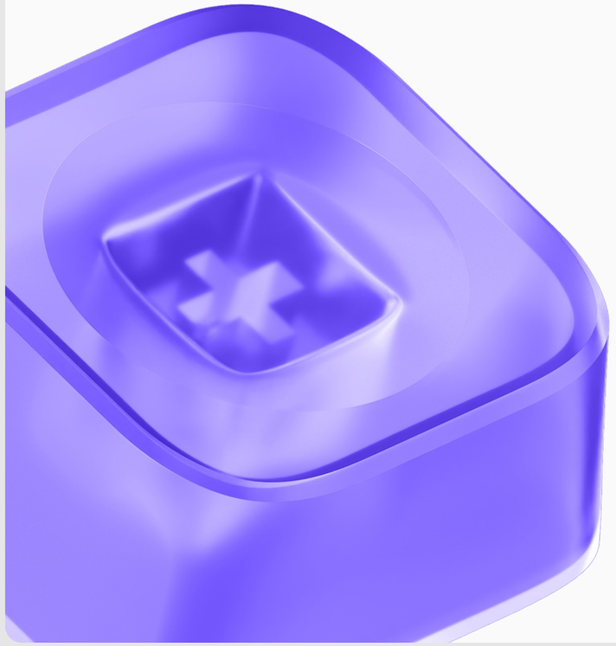


- Про курс Machine Learning
- Что нужно знать и на что будем опираться
- Как будет устроена работа на курсе

Про курс
Machine Learning



Факты про курс



01 Включает в себя все самые лучшие материалы из курсов по ML в ЦУ.

02 На разработку текущей версии материалов авторы затратили 150+ часов, на рефакторинг после первой волны — 70+ часов.

03 По отзывам студентов, в курсе — одни из самых крутых лонгридов (и материалов в целом!) ЦУ.

Для чего нужен курс

01

Разберётесь
в математических основах
ключевых методов
классического ML:
формальных постановках,
предположениях
и свойствах алгоритмов.

02

Научитесь применять
основные алгоритмы
на практике, в том числе
kNN, линейные модели,
деревья, разные
разновидности
бустинга и методы
детекции аномалий.

03

Соберёте базу, которую
чаще всего проверяют
на собеседованиях
у ML-инженера
и data scientist: от постановки
задачи и выбора метрик
до валидации
и интерпретациирезультатов.

Цель курса — собрать цельное понимание классического ML: от данных и метрик
до алгоритмов и интерпретации.

Как устроен курс

Блок 1. Основные термины машинного обучения и смежных областей. Оценка качества моделей	• Жизненный цикл ML-проекта • Метрики и функционалы потерь в задачах регрессии и классификации • Контроль качества и выбор моделей • Метрические алгоритмы
Блок 2. Линейные модели	• Линейная регрессия • Логистическая регрессия • Метод опорных векторов
Блок 3. Деревья решений и модели, основанные на них	• Решающие деревья, сложность алгоритмов и ансамбли • Случайные леса и градиентный бустинг • Аплифт-моделирование
Блок 4. Обучение без учителя и работа с признаками	• Кластеризация, снижение размерности и обнаружение аномалий • Генерация и отбор признаков • Интерпретация моделей и диагностика сдвига данных • Частые вопросы на собеседованиях по машинному обучению

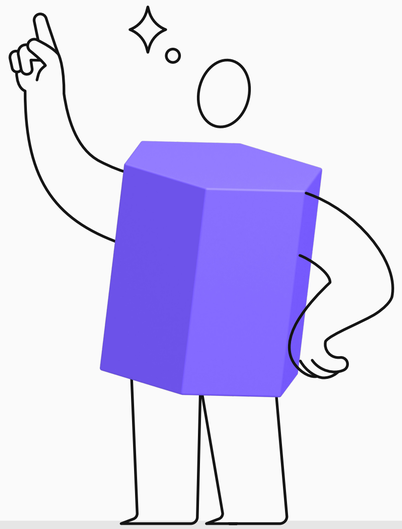
Как устроен курс

В каждой неделе курса:

- лонгрид с теорией и примерами,
- две лекции,
- семинар с упором на практику.

А ещё:

- домашние задания,
- соревнование и проект,
- коллоквиумы.



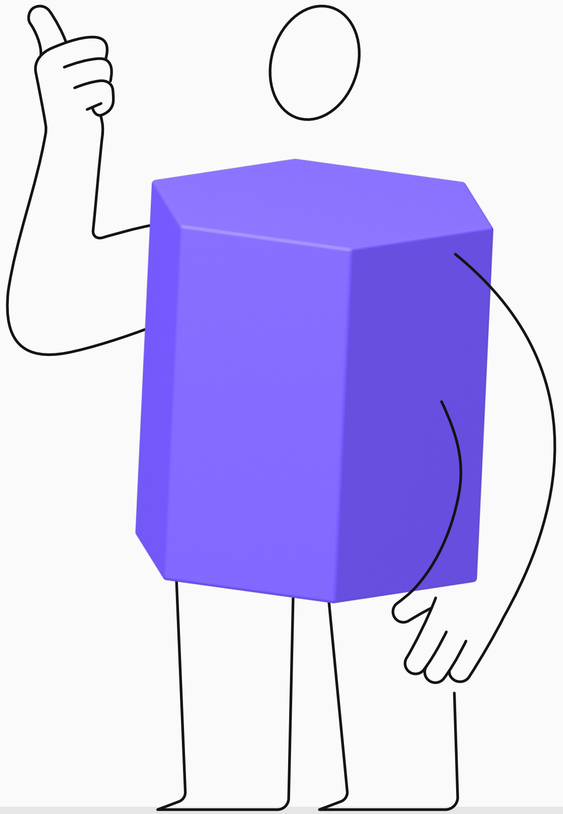
Как создавался курс

Авторы курса — эксперты в своей области — собрали максимум информации по теме ML и провели сравнительный анализ с другими продуктами на рынке.

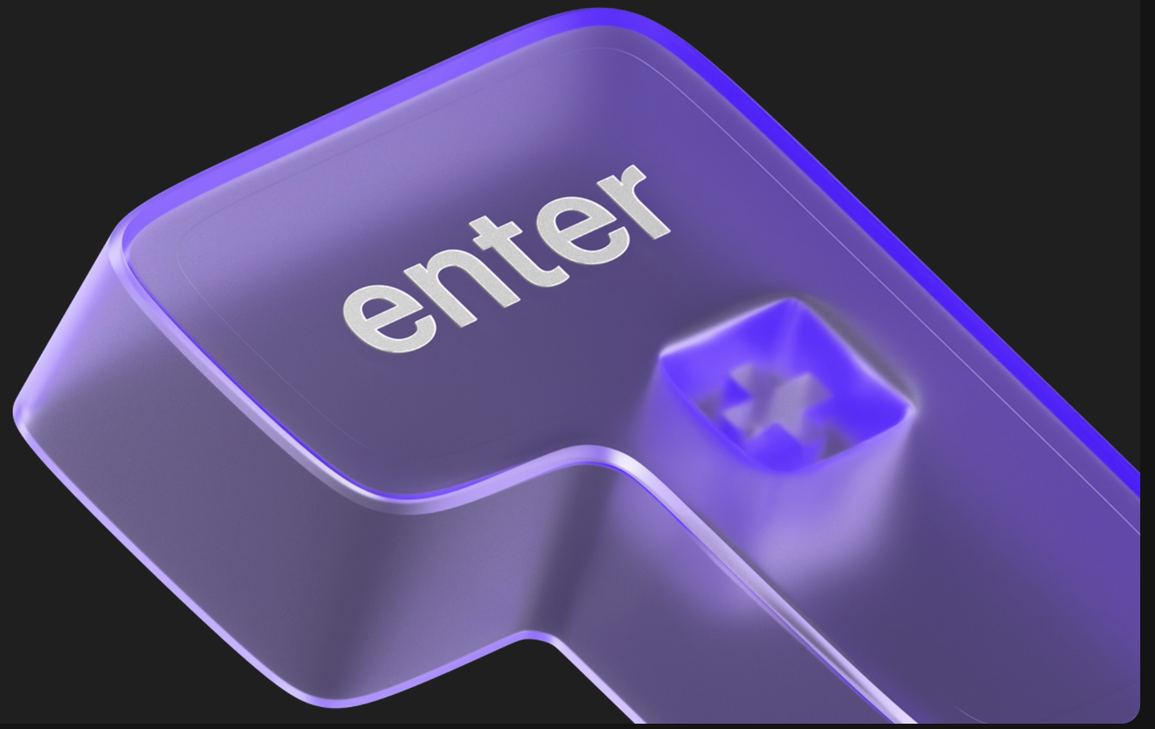
Сейчас этот курс — один из самых полных и детальных существующих курсов.

Некоторые темы пересекаются с курсом «Введение в искусственный интеллект», но раскрыты более подробно.

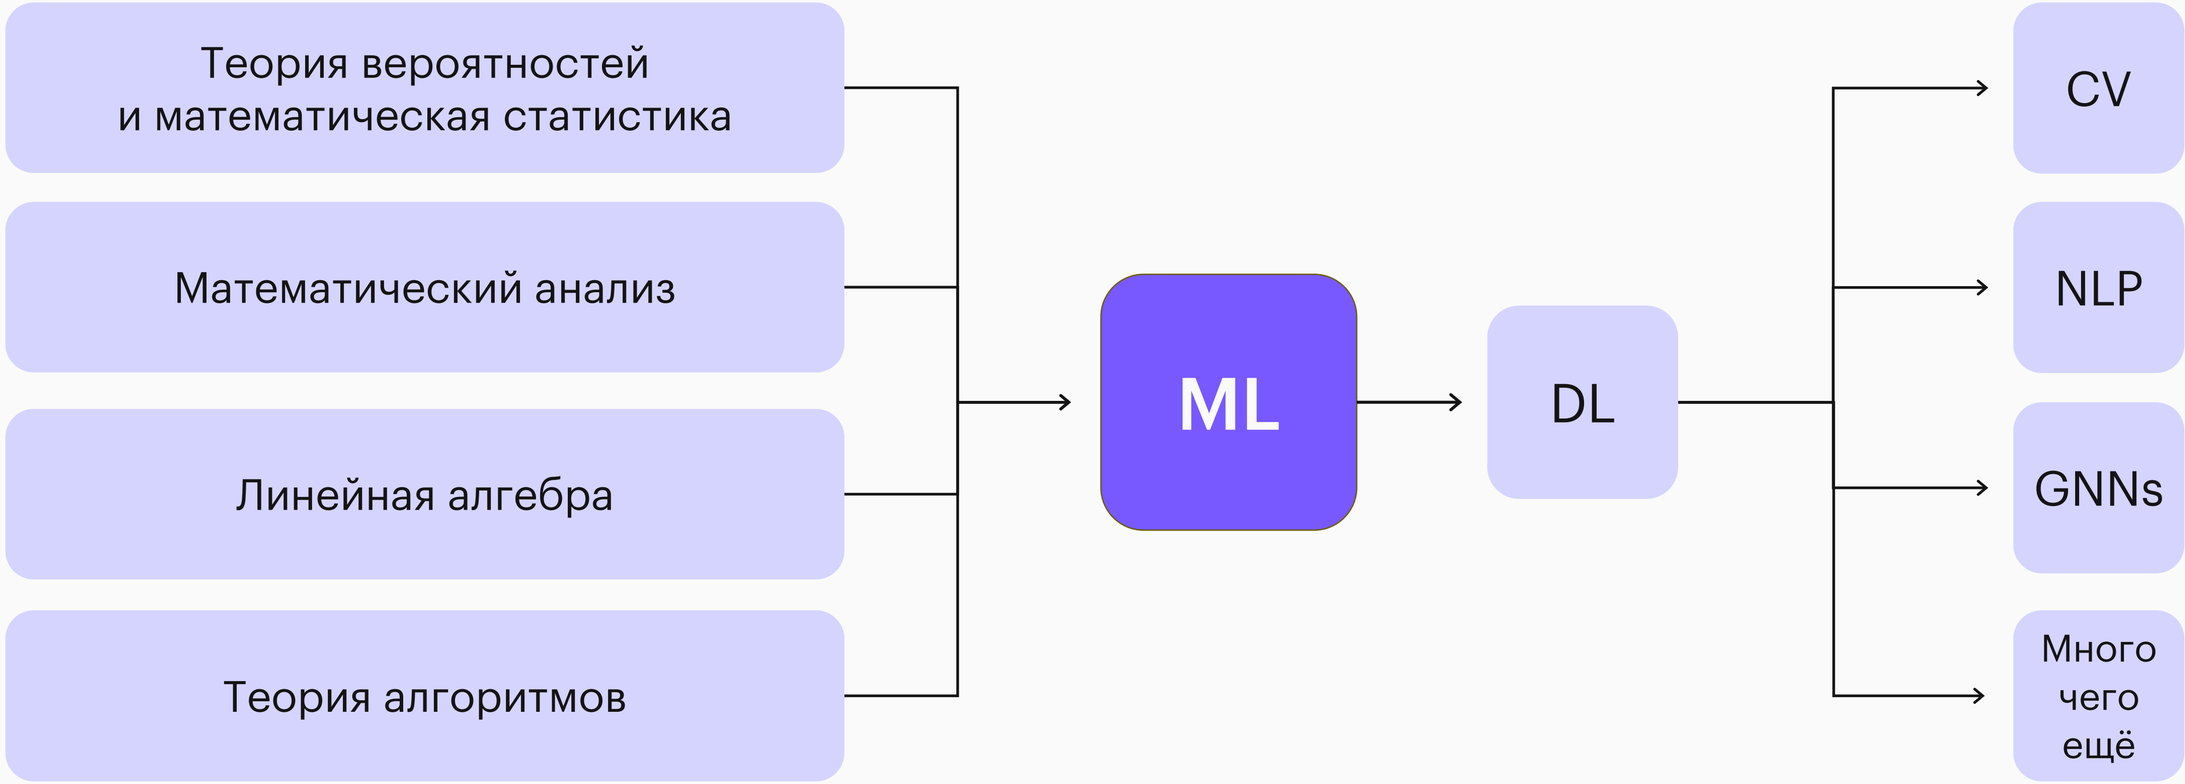
Про это поговорим далее.



Что нужно знать и на что будем опираться



Смежные дисциплины



Основные идеи, которых будем придерживаться в курсе

Цель курса — собрать цельное понимание классического ML: от данных и метрик до алгоритмов и интерпретации.

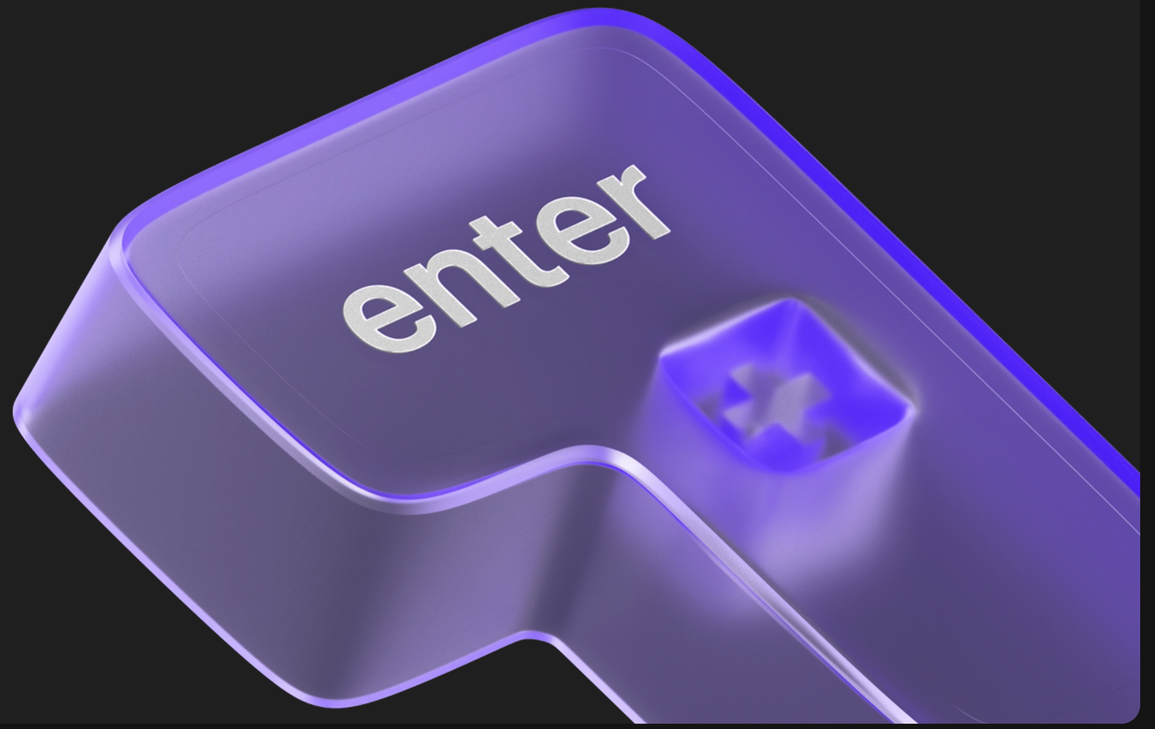
01 Разберём сложные вещи простыми словами.

02 При этом будут сложные моменты и темы (например, BVD и бустинги), которые потребуют особого внимания и вовлечения от вас.

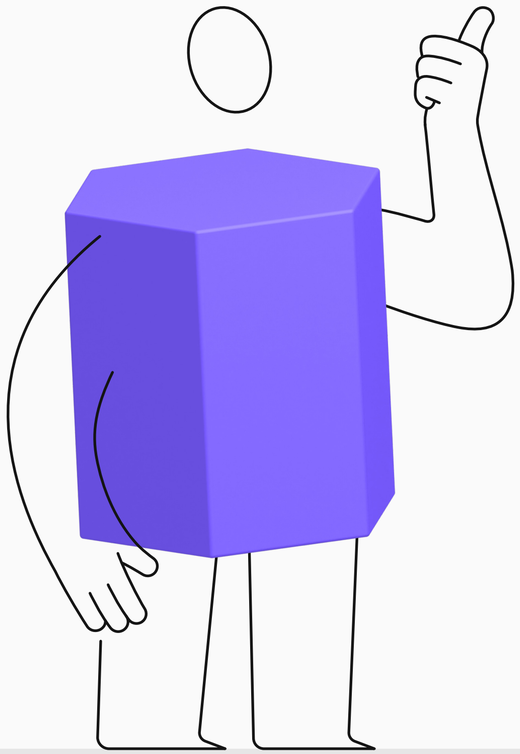
03 Сделаем акценты на практике и примерах.

04 Предоставим вам большое поле для закрепления знаний: домашки, соревнование, проект, коллоквиумы.

Как будет устроена работа на курсе



Итоговая оценка

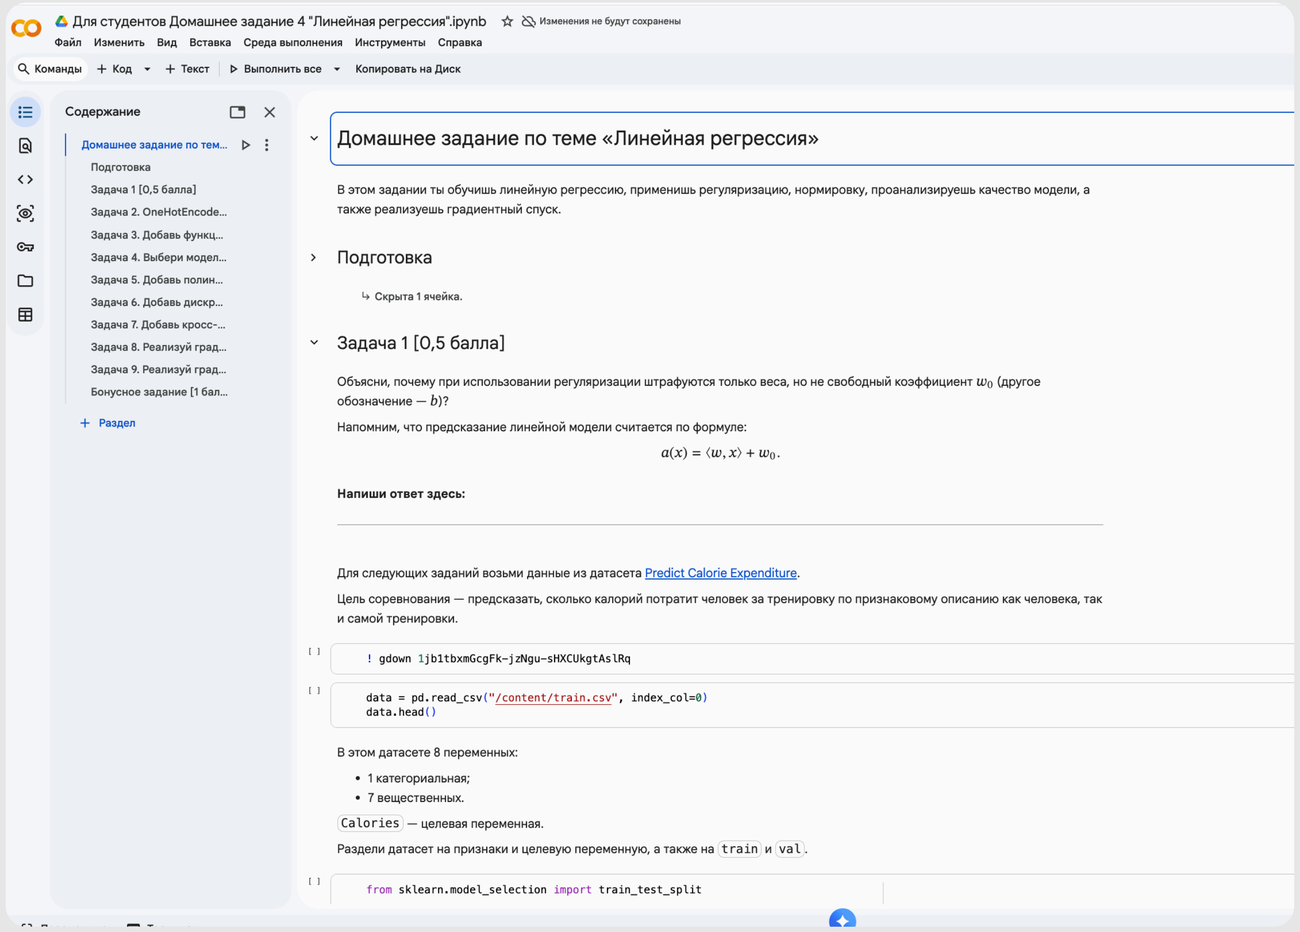


Активность	Вес	Количество	Описание
Домашние задания	30%	10	Набор задач по темам недели, включая Kaggle-style-соревнование с задачей по ML. Домашние задания выдаются еженедельно
Коллоквиум	30%	3	Письменная работа, которая включает в себя теоретические вопросы и практические задачи по пройденным материалам
Проект	20%	1	End-to-end-задача с данными на выбор студента, которая охватывает все темы курса. Проект защищается с презентацией перед аудиторией
Экзамен	20%	1	Письменная работа, которая включает в себя теоретические вопросы и практические задачи по пройденным материалам

Календарик

Номер недели	Тема	Домашнее задание	Коллоквиум
1	Жизненный цикл ML-проекта (ML lifecycle). Метрики и функционалы потерь в задаче регрессии	Домашняя работа 1	
2	Метрики и функционалы потерь в задаче классификации. Контроль качества и выбор модели	Домашняя работа 2	
3	Метрические алгоритмы	Домашняя работа 3	
4	Линейная регрессия	Домашняя работа 4	
5	Логистическая регрессия, метод опорных векторов (SVM)	Домашняя работа 5	
6	Решающие деревья	Домашняя работа 6	Коллоквиум 1. Линейные модели
7	Сложность алгоримтов. Ансамбли алгоритмов	Домашняя работа 7	
8	Случайные леса	Домашняя работа 8	
9	Градиентный бустинг	Домашняя работа 9	
10	Аплифт-моделирование	Соревнование	Коллоквиум 2. Модели на деревьях
11	Кластеризация и методы понижения размерности	Работа над проектом	
12	Обнаружение аномалий	Работа над проектом	
13	Генерация и отбор признаков	Работа над проектом	
14	Интерпретация моделей и диагностика сдвига данных	Работа над проектом	
15	Подведение итогов курса. Частые вопросы на собеседованиях по ML	Защиты проектов	Коллоквиум 3. Обучение без учителя, аномалии, работа с признаками, интерпретация

Домашки



Каждая классическая домашняя работа — Jupyter Notebook.

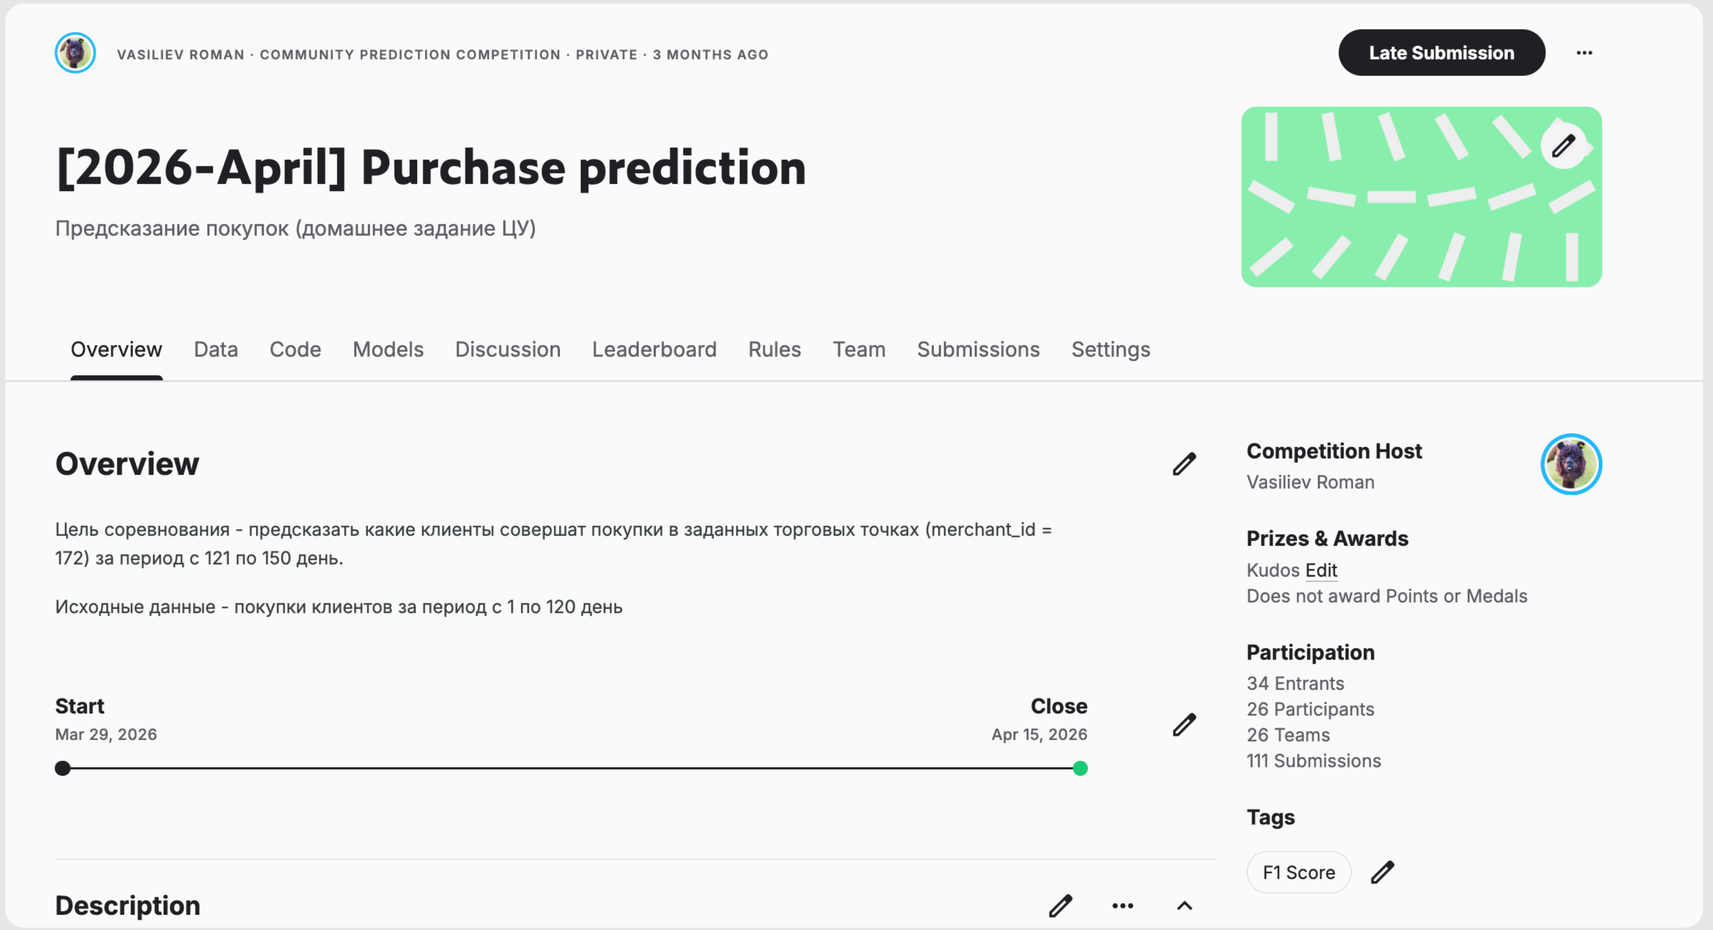
В домашках вы будете:

- экспериментировать с моделями,
- строить свои классы для моделей и сравнивать их с продовыми,
- МНОГО раз делать разведочный анализ данных,
- разбираться в технических особенностях алгоритмов.

1. Вы копируете его к себе в коллаб.
2. Заполняете пропущенные ячейки, отвечаете на вопросы.
3. Сдаёте решённый ноутбук.

→ Тут проговорить про GPT.

Одна из домашек — соревнование



Задача — побить бейзлайн
+ ворваться
в топ по скору.

Окончательно
с темой
определимся ближе
к его запуску.

Проект

1. Над проектом вы работаете 4 недели.
2. Работа идёт в командах, каждая команда будет регистрироваться и выбирать задачу (с согласованием семинариста).
3. В ходе проекта будут обязательные блоки в соответствии с неделями (работа с аномалиями, генерация признаков, интерпретация).
4. Оцениваются и итоговая реализация проекта, и сама защита.
   Защита — на последних неделях курса в рамках семинаров.

Проект на курсе Machine Learning

Работа ML-инженера не ограничивается обработкой данных и созданием моделей. Ещё нужно уметь работать в команде: договариваться, распределять роли в проекте, проводить совместные ресёрчи и обсуждать решения. А ещё — так презентовать заказчику результаты, чтобы стало понятно, как они решают задачу и в чём их ценность.

Этот проект — возможность потренироваться в решении командной задачи и на практике применить всё, что мы разобрали на курсе.

Дорожная карта проекта

Работа над проектом будет проходить поэтапно. Каждую неделю команды будут получать задание, связанное с темой курса. В нём будет указано, что именно нужно добавить или изменить в проекте, например провести анализ аномалий с учётом изученных методов или попробовать сгенерировать дополнительные признаки.

Задача команды — строить проект пошагово, интегрируя все элементы в единое решение.

Этапы проекта	Выдача задания	Чекпоинт
Сбор команды, выбор датасета, EDA	Тут будут актуальный для вас даты	
Работа с аномалиями и генерация признаков		
Интерпретация и диагностика моделей		
Подготовка презентации		

Коллоквиумы

На курсе будет **3 письменных коллоквиума.**

Важное

1. Проходят в рамках лекций, на неделях 6, 10 и 15.
2. Будут проходить письменно (задания на листочках А4, ответы — так же).
3. Включают в себя теоретические задачи и задачи на расчёты/вывод формул.
4. Имеют существенный вклад в итоговую оценку.

Экзамен будет проходить по аналогии с коллоквиумом.

Коллоквиум [демо-вариант]

Задача 1 (2.5 балла). Ответьте на вопросы по функционалам потерь и метрикам:

1. Опишите основные функционалы потерь и метрики для задачи бинарной классификации
2. Какой функционал потерь оптимизирует SVM? А логистическая регрессиия?
3. Что такое ROC-кривая? Какие выводы о классификаторе можно сделать на основе неё?
4. Какие существуют метрики задачи многоклассовой классификации?

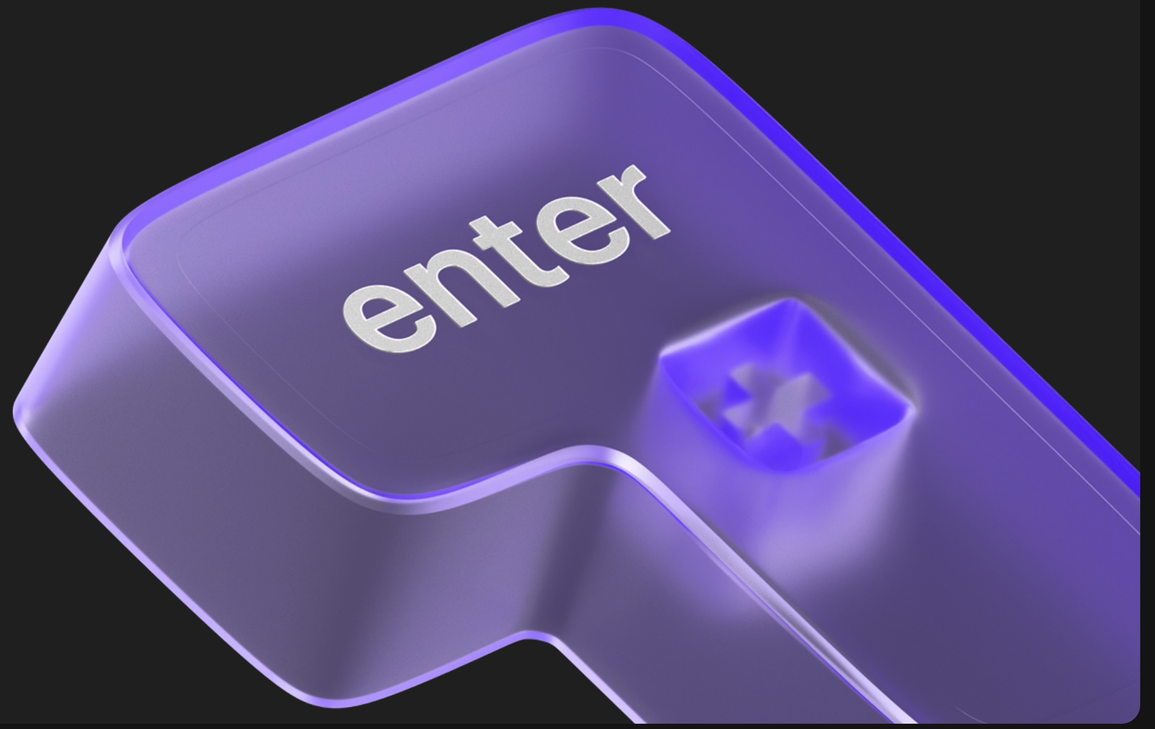
Задача 2 (2.5 балла). Решите задачу по метрикам бинарной классификации.

Для 6 объектов известны истинные метки классов $y_i \in \{0, 1\}$ и предсказанные моделью вероятности принадлежности к классу 1:

Объект i	1	2	3	4	5	6
Истинный класс y_i	1	0	1	0	1	0
Предсказанная вероятность $\hat{p}_i$	0.9	0.8	0.7	0.6	0.4	0.3

1. Используя порог $t = 0.5$, переведите вероятности в бинарные предсказания и вычислите:
   - Precision
   - Recall
   - F1-мера
2. Постройте ROC-кривую для этого классификатора, перебирая порог по всем возможным значениям.
3. Вычислите ROC-AUC.
4. Коротко объясните, что означает полученное значение ROC-AUC с точки зрения качества ранжирования объектов.

Преподаватели



Преподаватели (1/3)



Роман Васильев

Лид курса, лектор

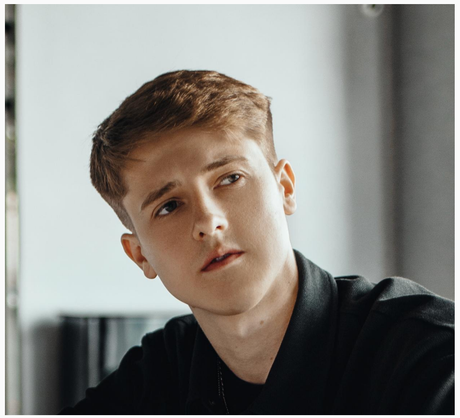
Chief Data Officer,
Т-Путешествия



Равин Бегалиев

Семинарист

Head of Analytics,
T-Shopping



Рафаэль Сайфутдинов

Семинарист

Аналитик комиссий для продавцов в Авито



Надежда Анисимова

Семинарист

МЛ-инженер,
Embedika

Преподаватели (2/3)



Даниил Хорец

Семинарист

Аналитик-разработчик,
Яндекс Такси



Максим Иванченко

Семинарист

Аналитик-разработчик,
Яндекс Search T&S



Михаил Курченко

Семинарист

Старший ML-инженер,
X5 Tech



Дима Сираков

Семинарист

Staff DS, Raif, CIB

Преподаватели (3/3): Прикладная и структурная биоинформатика



Роман Васильев

Лид курса, лектор

Chief Data Officer,
Т-Путешествия



Даниил Хлебников

Семинарист

Аспирант ФББ МГУ, м.н.с. ИОГен РАН; computational fellow в Altius Institute, Seattle, WA

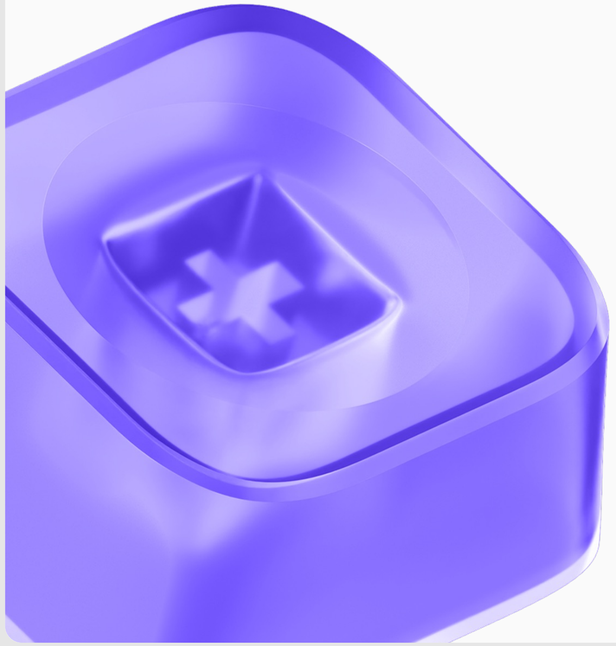


Владислав Мурзин

Семинарист

Выпускник ФББ МГУ,
Аналитик-разработчик,
Яндекс Еда

Итого



01 Курс покрывает собой весь классический ML, на котором потом будет держаться вся база.

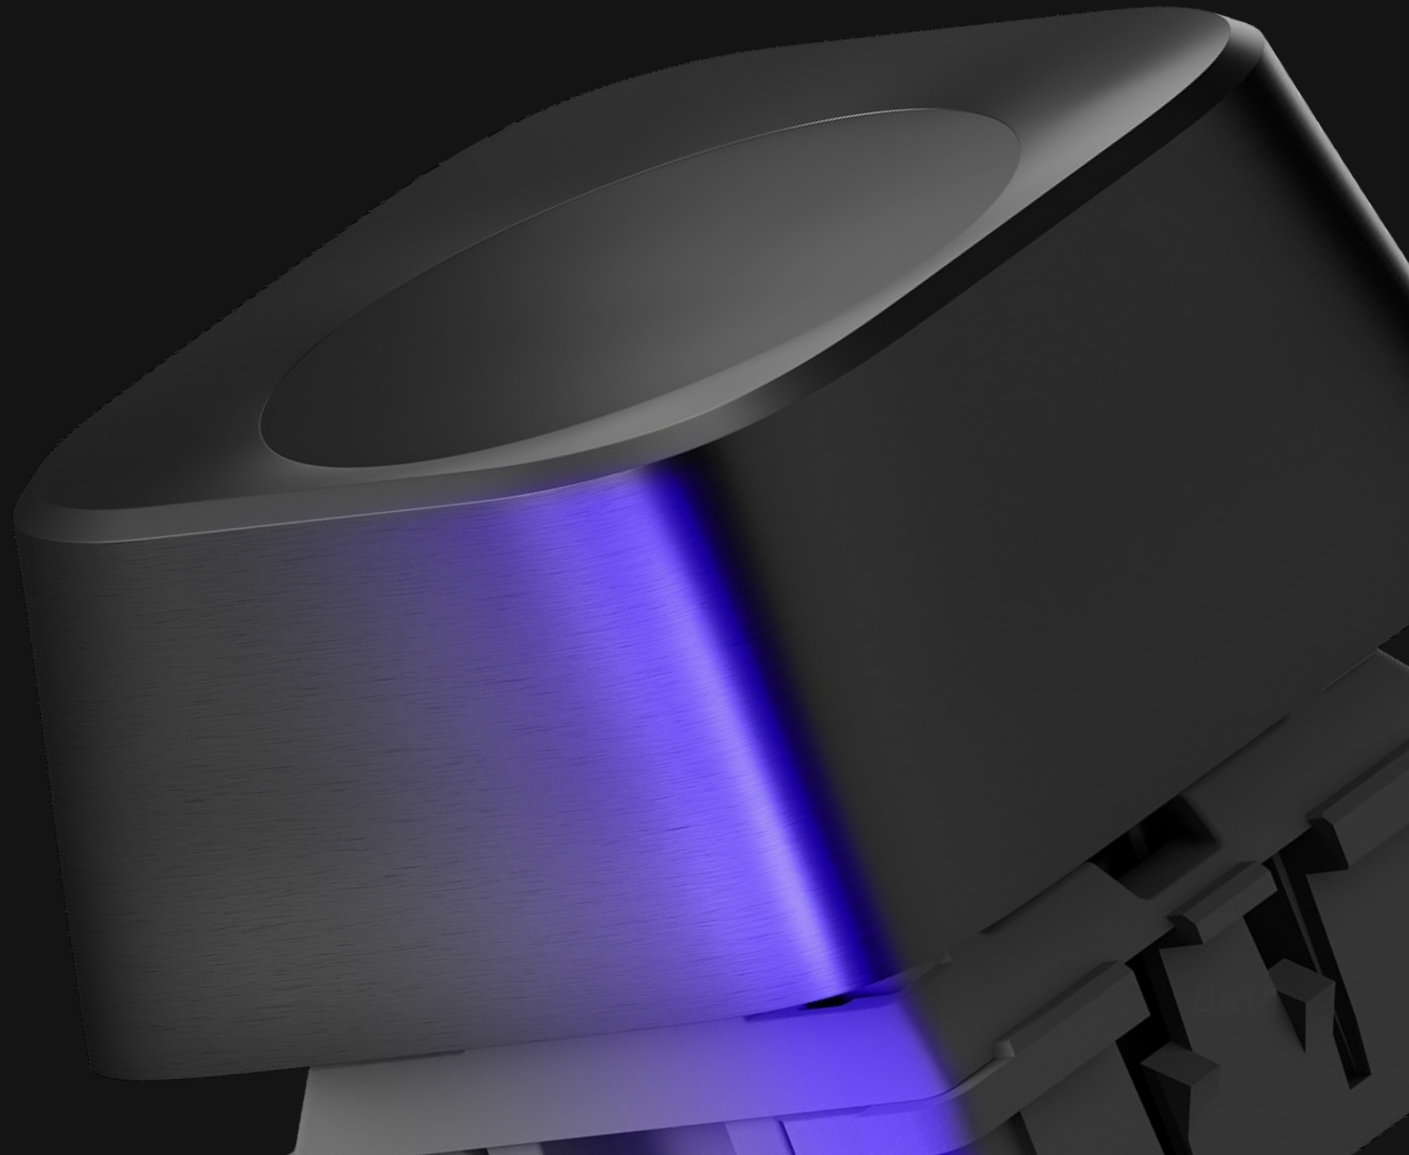
02 В курсе 4 модуля: термины и оценка качества моделей, линейные модели, модели на деревьях, обучение без учителя и работа с признаками.

03 Чтобы хорошо сдать курс, нужно:

- делать все домашки и затащить соревнование;
- **важно:** хорошо подготовиться к коллоквиумам и экзамену;
- выбрать качественную задачу для проекта и отлично реализовать её.

Цель курса — собрать цельное понимание классического ML: от данных и метрик до алгоритмов и интерпретации.

ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ



Вопросы