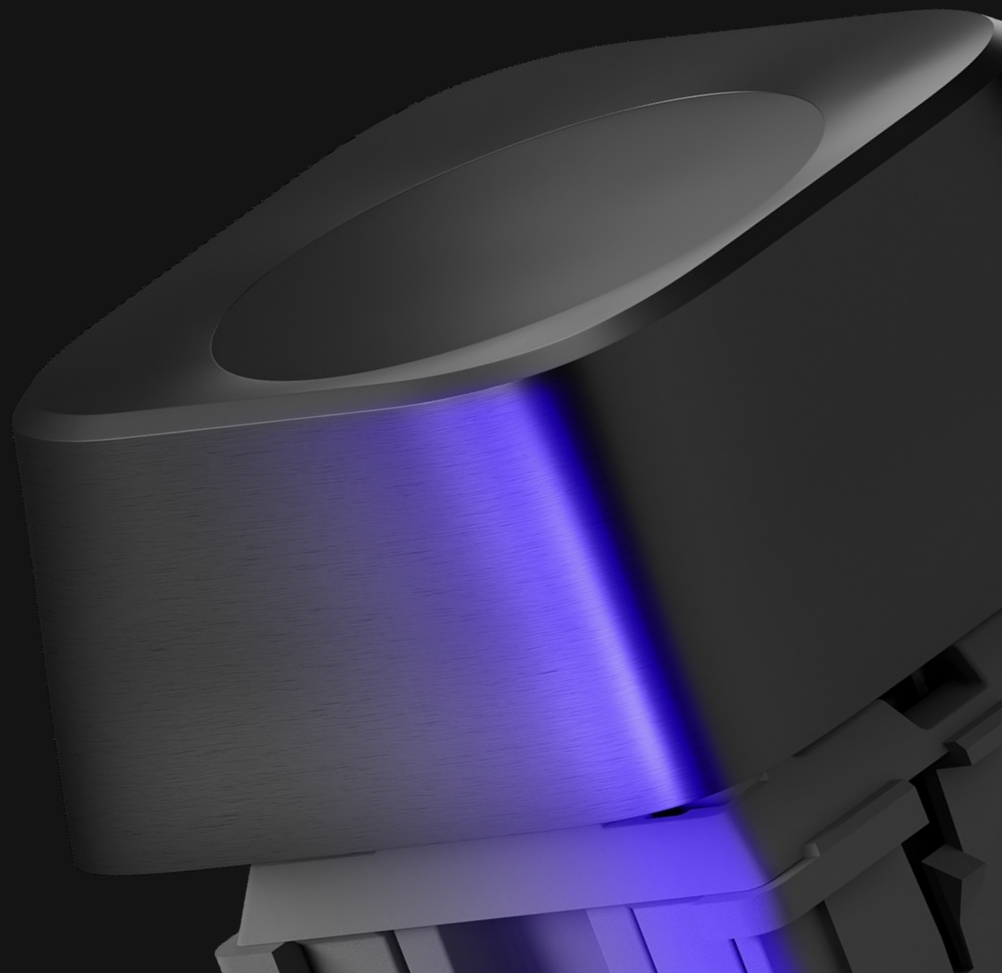
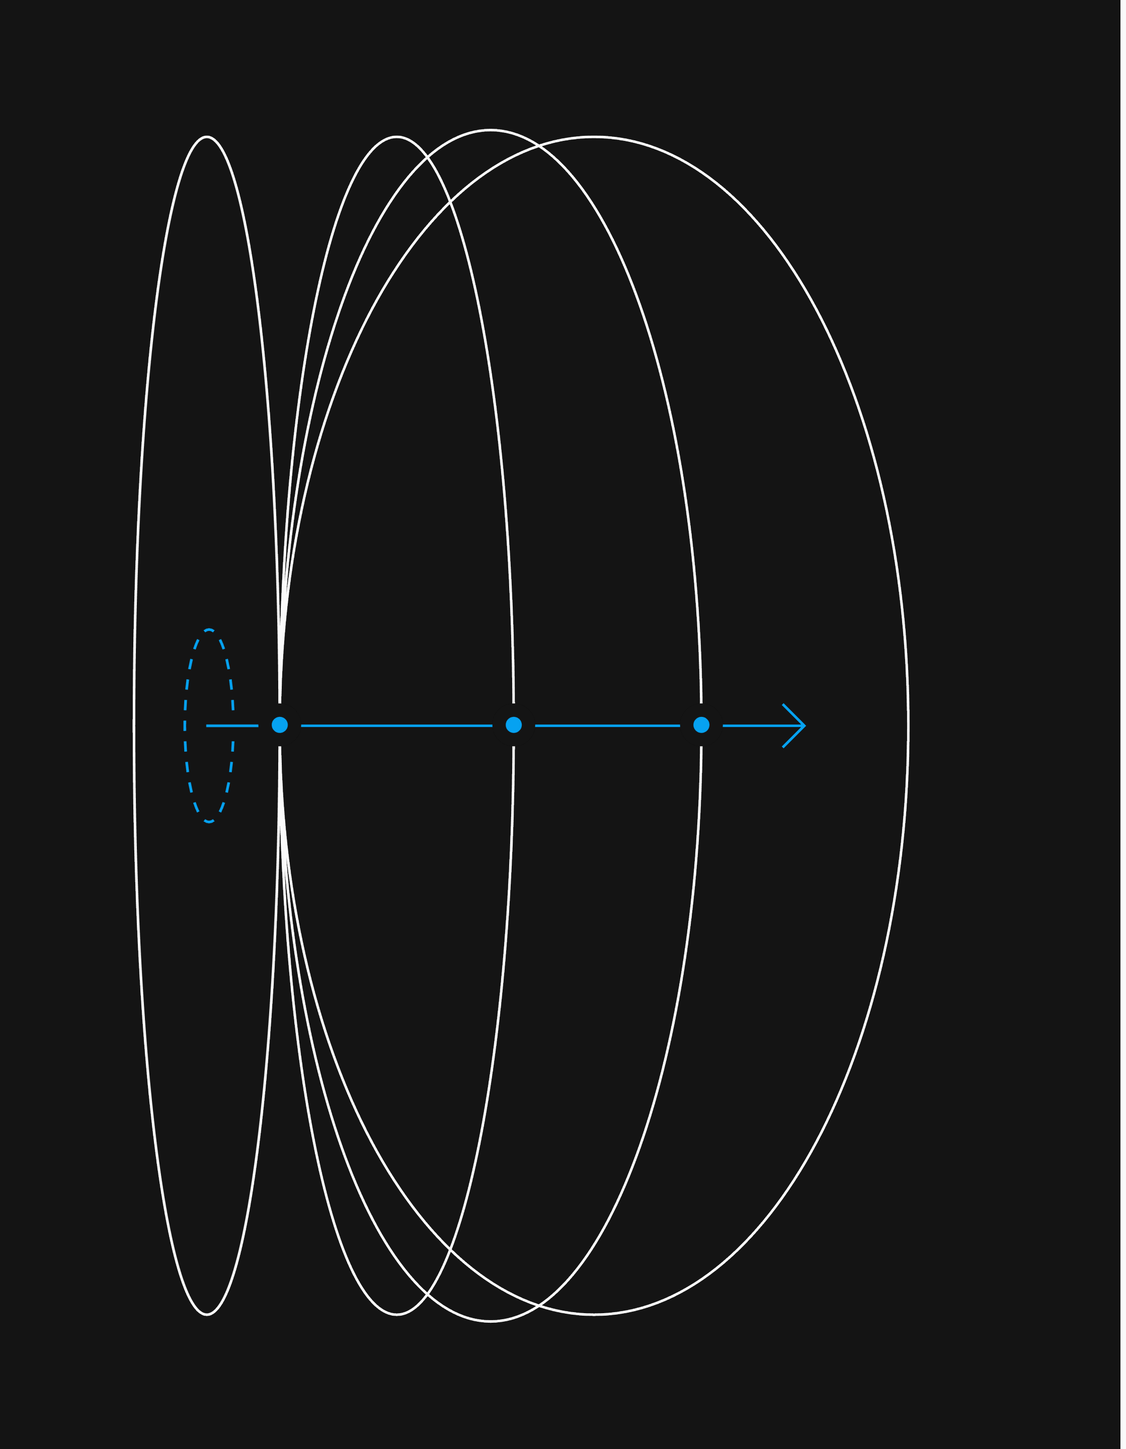
ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ

Интро в курс. ML lifecycle. Метрики и функционалы потерь в задаче регрессии



ML
Машинное обучение

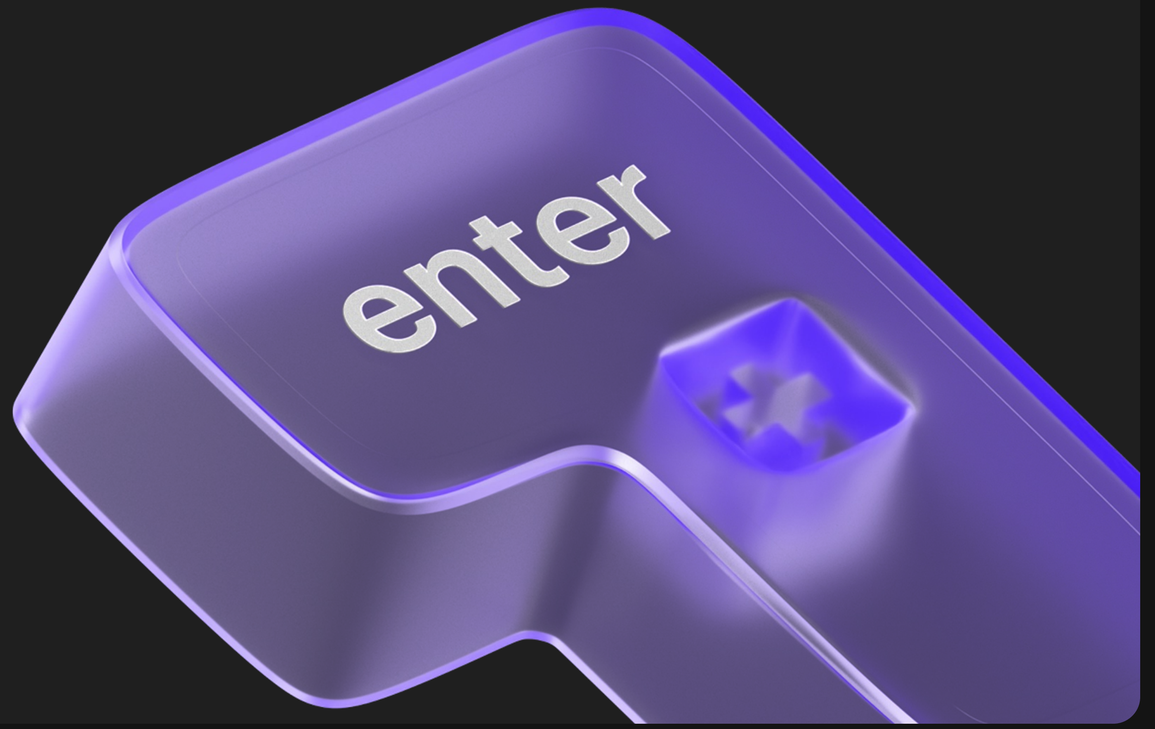
01



План лекции

- Про курс Machine Learning
- Процесс обучения ML-моделей
- Основные термины ML
- Метрики и функционалы потерь в задаче регрессии

Про курс Machine Learning



Для чего нужен курс

01

Узнаете про ключевые концепции машинного обучения, которые будете использовать в дальнейших курсах.

02

Научитесь применять алгоритмы на практике: kNN, линейную регрессию, бустинги и алгоритмы детекции аномалий.

03

Получите базовые знания в классическом ML. Про него чаще всего спрашивают на собеседованиях на ML-инженера/DS.

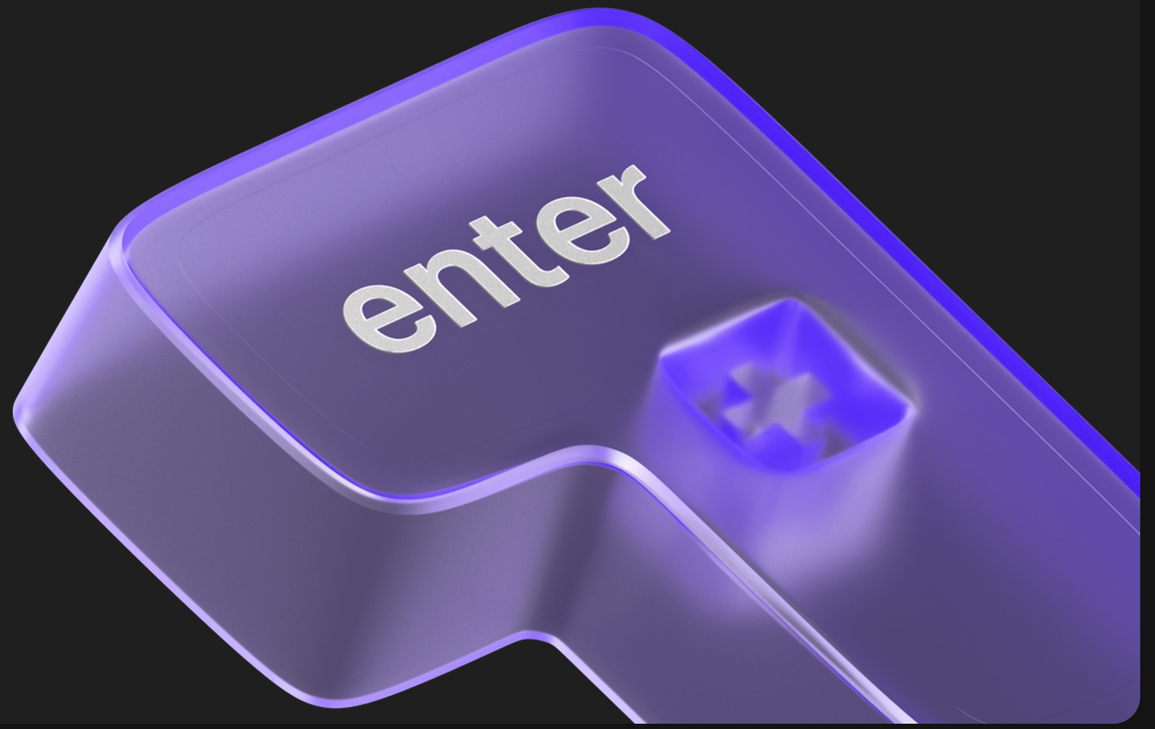


Этот курс — не про нейросети, он про базу. А без базы — никуда.

Как устроен курс

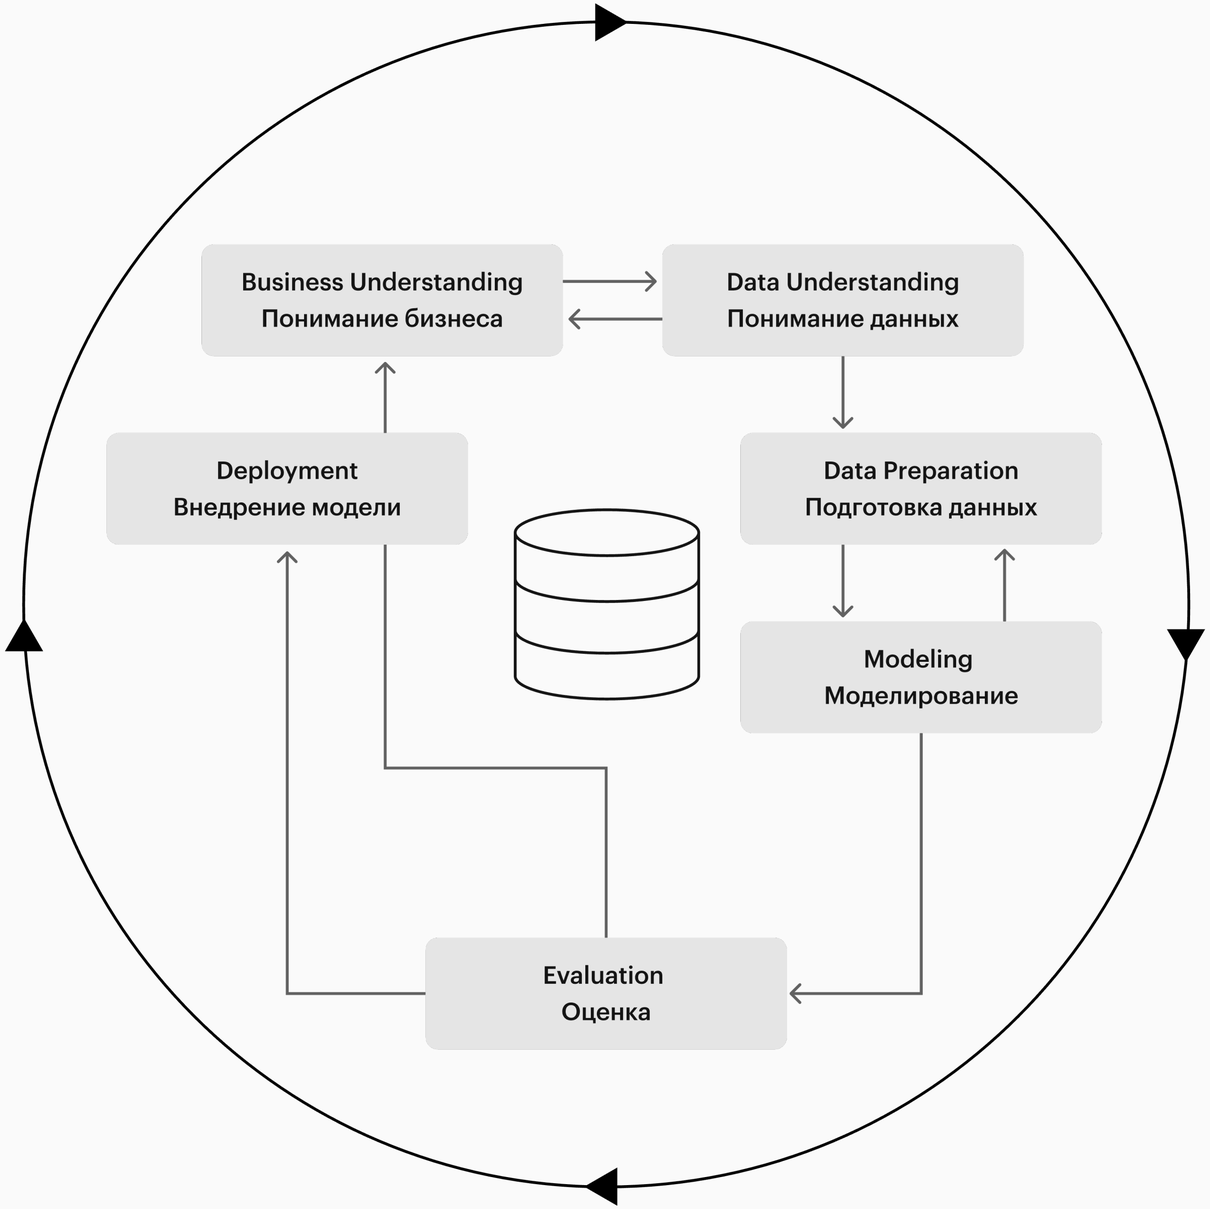
Блок 1. **Основные термины машинного обучения и смежных областей. Оценка качества моделей**	• Ключевые понятия машинного обучения • Метрики и функционалы потерь • Различные способы оценок моделей
Блок 2. **Линейные модели**	• Линейная регрессия • SVM • Логистическая регрессия
Блок 3. **Деревья решений и модели, основанные на них**	• Обучение решающих деревьей и ансамблей, в том числе градиентных бустингов • Узконаправленные подходы, в частности аплифт-моделирование
Блок 4. **Обучение без учителя и работа с признаками**	• Классические методы обучения без учителя • Методы генерации и отбора признаков • Интерпретация моделей

Процесс обучения ML-моделей



CRISP–DM

Cross-Industry Standard
Process for Data Mining



Современный ML Lifecycle

Схема решения задачи

01 Уточнение и постановка задачи (Problem Definition)

понимание бизнес-проблемы, математическая формализация

02 Сбор, подготовка и анализ данных (Data Mining)

- понимание исходных данных
- сбор данных (Data collection)
- предобработка данных (Data cleaning) / подготовка данных для модели
- разведочный анализ (Exploratory Data Analysis)

Машинное обучение (Machine Learning)

03 Выбор

Алгоритма
- модели (Model selection)
- способа обучения: гиперпараметры, методы оптимизации

Контроля
- функции ошибки (Metric selection)
- способа контроля (разбиение train/test/valid)

Признаков
- генерация (Data coding = feature engineering)
- селекция (feature selection)

04 Обучение (fit)

05 Предсказание (predict) и проверка качества (evaluation)

(может ещё постобработка Post-processing)

06 Deploy / Release / Online evaluation / Debug / Monitoring / Maintenance

переобучаем алгоритм на всех данных

07 Отчётность, презентация, коммуникация

визуализация данных, модели, результатов

Уточнение и постановка задачи (Problem Definition)

Результат этапа

- Понимаем, какую бизнес-проблему решаем — и точно ли нужно использовать ML.
- Выясняем, какую бизнес-метрику оптимизируем.
- Связываем техническую метрику с бизнес-реалиями.
- Формализуем задачу: классификация/регрессия/ранжирование.
- Уточняем ограничения (время, технические ограничения) и пожелания (интерпретируемость).
- Продумываем, как будем использовать решение на практике и как оценивать успех: офлайн-метрики, A/B-тест, бизнес-индикаторы.

Сбор, подготовка и анализ данных (Data Mining)

Результат этапа

- → Проверили, достаточно ли данных для решения задачи (объём, качество, доступность в проде).
- → Учли особенности: дисбаланс классов, пропуски, выбросы, шум — знаем, как с ними работать.
- → Провели ревизию данных: поняли смысл признаков, проверили валидность, зафиксировали потенциальные проблемы.
- → Если данных нет — знаем, как и где их собирать (базы данных, API, логи, внешние источники).
- → Продумали процесс разметки (если нужна): кто, как и чем проверяет качество.
- → Провели очистку и подготовку данных: пропуски, выбросы, шум — не просто убрали, а осмыслили.
- → Сделали EDA: поняли структуру данных, выявили зависимости, построили первичные гипотезы.
- → Подготовили готовый датасет для модели и список гипотез/наблюдений для дальнейшей работы.

Выбор алгоритма, признаков и способа контроля модели

Результат этапа

Выбран алгоритм (Model Selection):

- Понимаем, какую модель используем и почему (учли ограничения по времени обучения, инференса, интерпретируемости, объёму данных).
- Не гонимся за модой, выбираем подходящий инструмент: часто это бустинг, но в ряде случаев — простые модели.

Определён способ оценки качества (Metric Selection):

- Чётко понимаем, какую метрику и Loss используем: что оптимизируем при обучении, что замеряем при валидации.
- Продумали способ валидации: Train/Test Split, k-Fold, Time Series Split — в зависимости от задачи.

Подготовлен набор признаков (Feature Engineering):

- Сгенерировали новые признаки, если нужно (например, из даты: день недели, час, is_weekend).
- Отобрали релевантные фичи, убрали лишнее, минимизировали шум.
- Проверили, нет ли Data Leakage (модель не должна «подглядывать» в будущее).

Есть план по обучению модели:

- Понимаем, как будут идти обучение, подбор гиперпараметров, сравнение моделей.
- Знаем, какие эксперименты будем проводить и какие вопросы они должны закрыть.

Обучение модели (Fit)

Результат этапа

- → Модель обучена на данных.
- → Используем только те признаки, которые реально доступны в проде, чтобы не было странных моментов на тестах.
- → Обучение идёт с учётом валидации и контроля переобучения:
  - Следим за поведением метрик на обучении/валидации.
  - Проверяем, не случилась ли утечка данных (Data Leakage).
  - Отслеживаем переобучение (например, сильный провал на тесте).
- → Сравниваем разные модели/подходы: иногда простая модель работает лучше сложной, важно это проверить.
- → Итеративно дорабатываем пайплайн, если нужно: возвращаемся к признакам, алгоритму, настройкам.

Предсказания и оценка качества (Predict & Evaluation)

Результат этапа

- Провели честную оценку модели: предсказания делаем только на новых данных.
- Считаем метрики по плану, заранее выбранному (не подстраиваем метрики под результат постфактум).
- Сравнили с бейзлайном: новая модель действительно лучше?
- Связали ML-метрики с бизнес-метриками: понимаем, как увеличение точности влияет на деньги/процесс.
- Оценили устойчивость модели: нет ли случайных всплесков качества из-за удачного разбиения данных?
- Подумали, нужна ли постобработка предсказаний: сглаживание, калибровка, кастомные правила.
- Проверили, совпадает ли результат с ограничениями и планами, зафиксированными на этапе постановки задачи.

Deploy / Release / Online Evaluation / Debug / Monitoring / Maintenance

Результат этапа

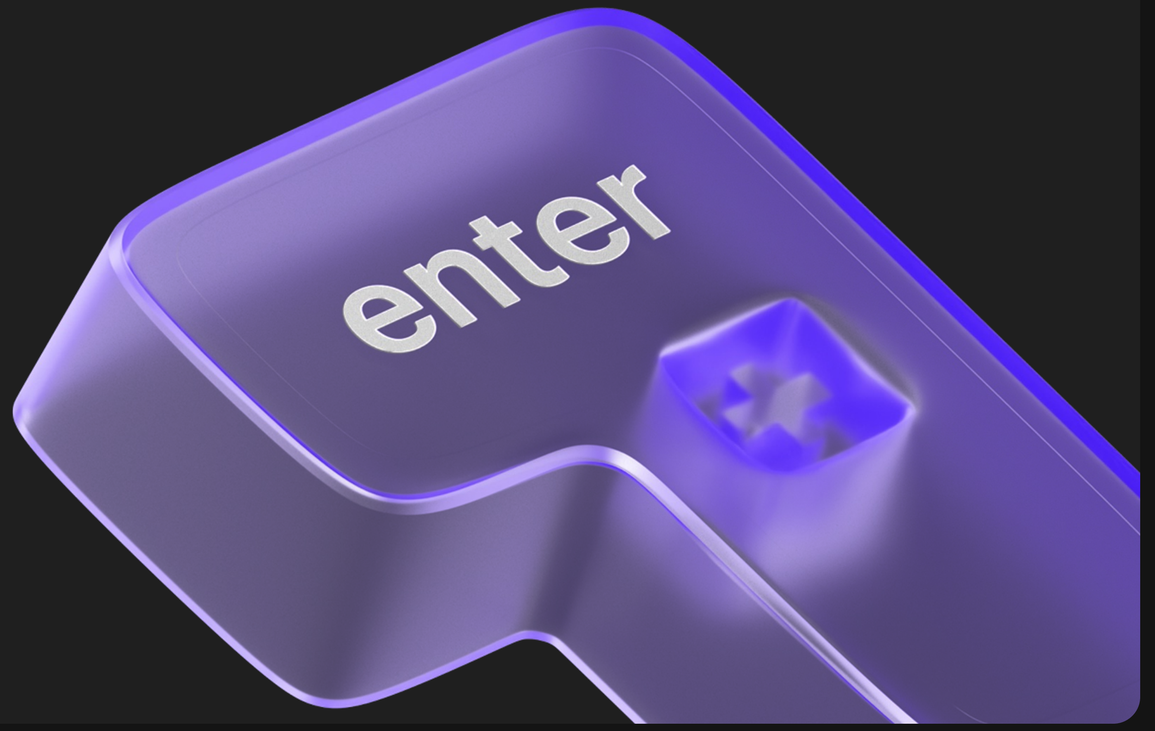
- Модель готова к продакшену: перевели из ноутбука в реальную систему (через API, пайплайны, ML-сервисы).
- Переобучили модель на всех доступных данных перед релизом — чтобы использовать максимум информации.
- Настроен мониторинг: следим за качеством предсказаний, скоростью, стабильностью работы.
- Готовы к отладке и поддержке: предусмотрены логи, алёрты на подозрительное поведение.
- Понимаем, что модель устаревает — есть план регулярного переобучения или обновления.
- Учли инфраструктуру: договорились, кто за что отвечает при работе модели.

Отчётность, презентация, коммуникация, документация

Результат этапа

- Готова презентация результатов: понятно объясняем, что сделали, зачем и что это даёт бизнесу.
- Показали не только результат, но и контекст: как работала модель, какие были ограничения, каковы риски.
- Оформлена документация: что делали, какие гипотезы проверяли, какие решения принимали и почему.
- Визуализация: графики, дашборды, инфографика, чтобы показать не только «что получилось», но и «почему».
- Провели коммуникацию с командой и заказчиком: согласовали результат, поняли, нужны ли доработки.
- Обсудили дальнейшие шаги: нужен ли релиз, итерации, поддержка, следующий этап развития модели.

Основные термины ML



Пространство объектов X

Пространство меток Y

Целевая функция $y(x)$

Примеры объектов $x \in X$

→ пациенты

→ клиенты банка

→ месторождения

→ описания проектов

→ описания недвижимости

observation / example / instance / object

Примеры меток $y \in Y$

→ {здоров, грипп, ангина, ковид}

→ {мошенник, честный}

→ {есть золото, нет золота}

→ доход от реализации

→ стоимость

target / response / outputs / dependent variable

Есть неизвестная целевая зависимость $y(x): X \to Y$

Задача обучения с учителем

Дано

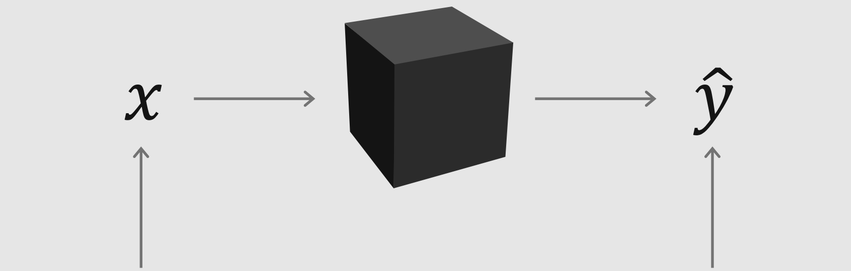
Обучающая выборка —
конечное множество объектов
с известными метками.

$$X_{\text{train}} = \{(x_1, y_1), \dots, (x_m, y_m)\}$$

$$y(x_1) = y_1$$
$$\dots$$
$$y(x_m) = y_m$$

Найти

Алгоритм  — способ оценивать
метки на новых объектах.



Цели решения ML задачи

01

Восстановление целевой зависимости

Уметь восстанавливать метки новых объектов $y(x)$ — найти зависимость целевой переменной от остальных.

02

Интерпретация

Как устроена y(x).

03

Оценка качества полученного решения

Например, насколько ошибаемся в среднем, что ждать при использовании нашего прогноза.

Типы задач обучения с учителем

Классификация (Classification)

$$|Y| = k << \infty$$

Бинарная

$Y = \{0, 1\}$ или $Y = \{-1, +1\}$

Скоринговая бинарная

$a(x) \in [0, 1]$

На k непересекающихся классов (Multiclass Classification)

$$Y = \{1, 2, \ldots, k\}$$

На k пересекающихся классов (Multilabel Classification)

$$Y = \{0, 1\}^k$$

Регрессия (Regression)

$$Y = \mathbb{R}$$

Многомерная регрессия

$$Y = \mathbb{R}^l$$

Прогнозирование (Forecasting)

$$X_{\text{train}} = \{(x_1, t_1, y_1), \ldots, (x_m, t_m, y_m)\}$$

$$t_1 \le t_2 \le \ldots \le t_m$$

Пространство объектов

Например:

- медицинские истории
- тексты
- сигналы / временные ряды / последовательности изображения
- векторы / множества / графы
- ...

Для удобства последующих рассуждений:

$X = \mathbb{R}^n$ — n-мерное признаковое пространство.

$x_i = (x_{i1}, \dots, x_{in})$ — объект в признаковом описании.

x_{ij} — j-й признак.

inputs / attributes / regressors / properties / covariates / features / variables

Задача в признаковой постановке

Матрица «объект — признак» (Data Matrix).

описание объекта

класс объекта (целевая переменная)

номер клиента	пол	возраст	поведение_30–59_дней	debt_ratio	доход	**вернёт кредит?**
0	М	46	0	1.329588	800.0	0
1	Ж	69	0	0.535122	3800.0	1
2	М	77	0	0.169610	3000.0	0
3	М	58	1	2217.000000	NaN	0
4	x_{41}	x_{42}	x_{43}	x_{44}	x_{45}	y_4

ПО СТРОКАМ

Признаковые описания объектов

ПО СТОЛБЦАМ

Значения конкретных признаков

Целевой признак

Target

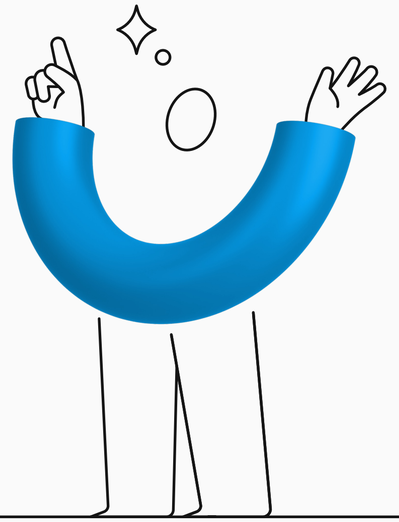
Задачи классификации — целевой признак категориальный.

Задачи регрессии — целевой признак вещественный.

Целевой признак может быть любым.
Например, графом!

Замечание

Целевой признак «условен».
Часто просто дана матрица
(целевой признак приходится формировать).



Классическое обучение

Данные заранее категоризированы (или численные)

Данные никак не размечены

С учителем

Предсказать категорию

Классификация

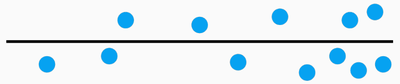
«Разложи носки по цвету»



Предсказать значение

Регрессия

«Разложи галстуки по длине»



Без учителя

Разделить по схожести

Кластеризация

«Разложи похожие вещи по кучкам»



Выявить последовательность

Ассоциация

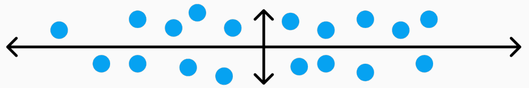
«Найди какие вещи я часто ношу вместе»



Найти зависимости

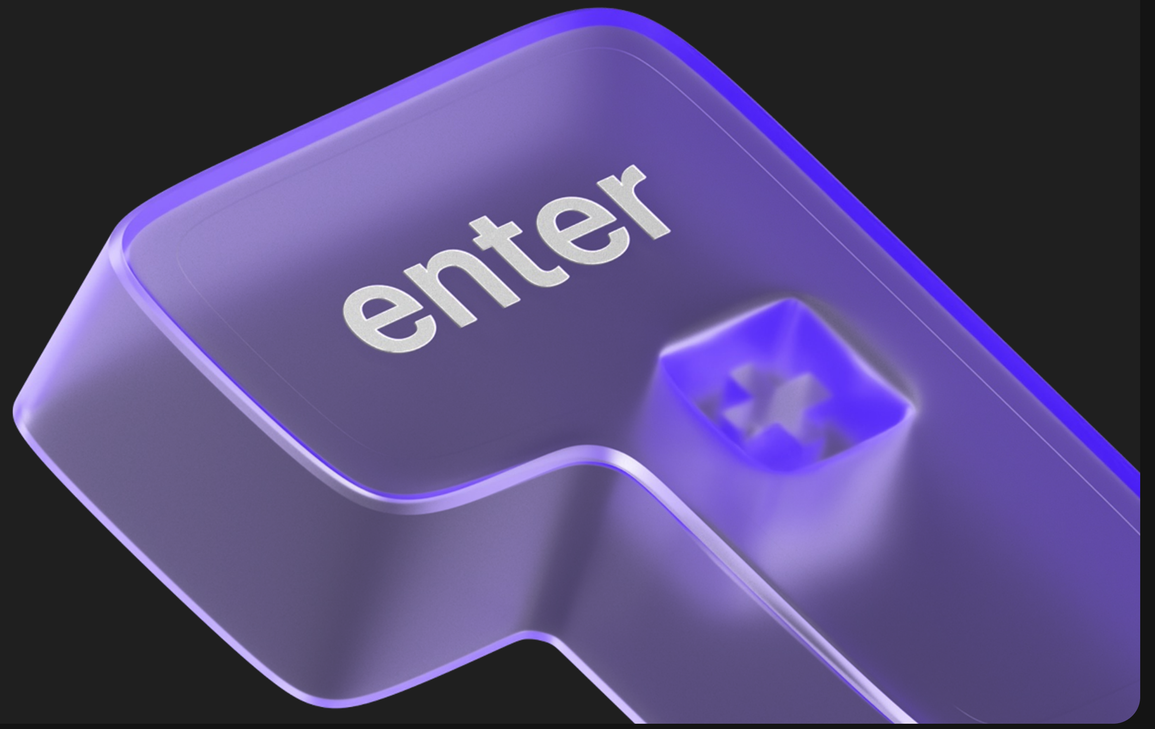
Уменьшение размерности (обобщение)

«Собери из вещей лучшие наряды»



Источник

Метрики и функционалы потерь в задаче регрессии



Метрики и функционалы потерь

ML-метрика — это способ количественно оценить качество работы модели, сравнивая её предсказания с истинными значениями.

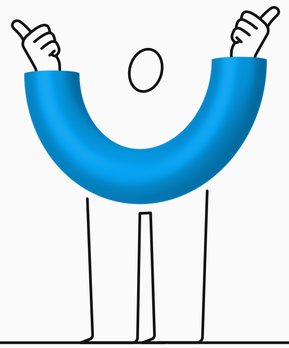
Функционал потерь (Loss Function / лосс / Loss) — это формализованная функция ошибки, которую модель оптимизирует во время обучения.

Метрику нужно выбирать с учётом целей и контекста применения модели.

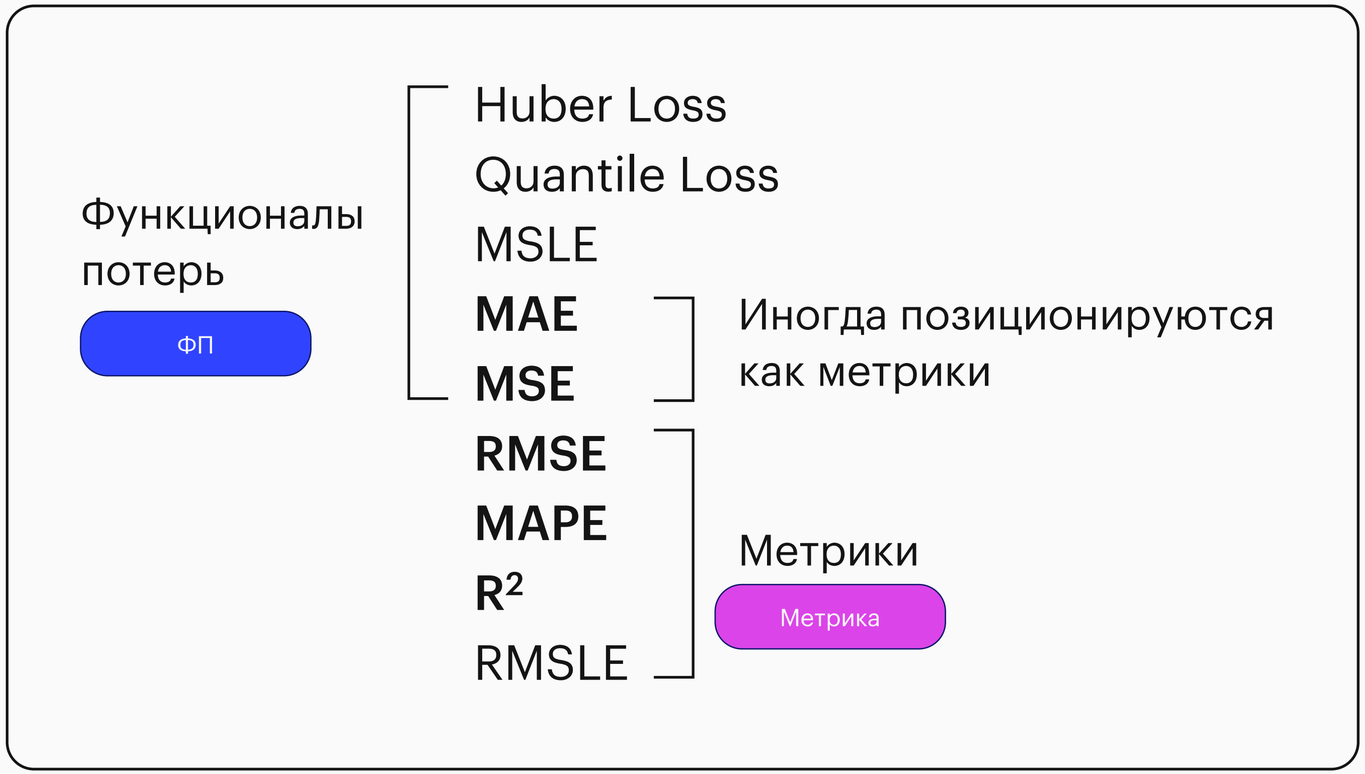
Метрики используют:

- во время валидации и тестирования;
- при сравнении нескольких моделей или конфигураций;
- в процессе мониторинга качества модели в production-среде.

Именно Loss сообщает алгоритму, насколько «плохо» текущее предсказание и как нужно обновить параметры/веса модели.



Метрики и функционалы потерь в задаче регрессии



Здесь:

→ **функционалы потерь** — функции, на которых можно напрямую обучать модель;

→ **метрики** — те индикаторы, которые стоит замерять для представления результатов бизнесу.

Рабочий пример



Объекты	$\hat{y}_i$, Прогноз **млн ₽**	y_i, Факт **млн ₽**	$y_i - \hat{y}_i$, Ошибка, **млн ₽.**
Коммуналка	5	4	-1
Студия	5	6	+1
Однокомнатная	8	10	+2
Двухкомнатная	12	16	+4

Хотим получить одно число, которое будет характеризовать качество работы модели.

Источник

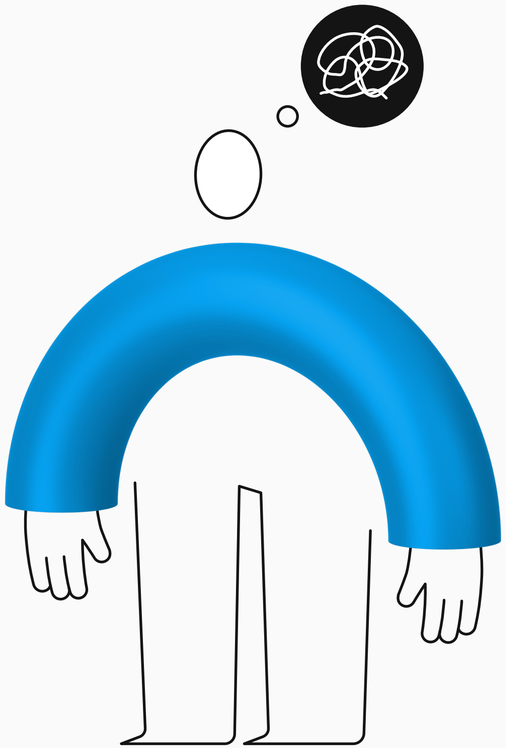
Обозначения

y_i — истинное значение таргета для объекта i

$\hat{y}_i$ — предсказание модели для объекта i

n — количество наблюдений (объектов в выборке)

$\bar{y}$ — среднее значение таргета по всем объектам

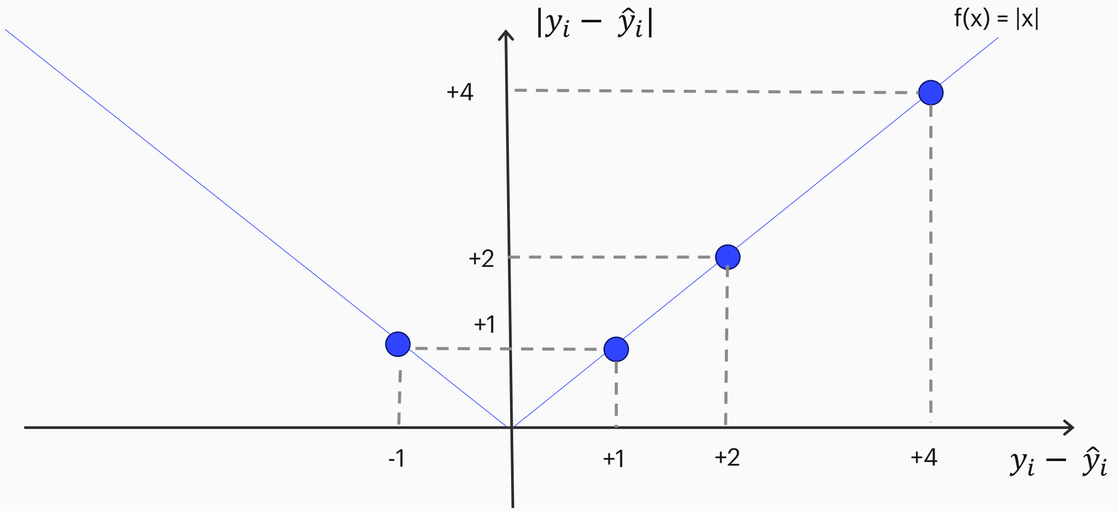


MAE: средний абсолютный размер ошибки

Mean Absolute Error

ФП Метрика

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$



Преимущества

- Легко интерпретировать.
- Измеряется в единицах таргета.
- Удобна, когда все ошибки нужно учитывать равномерно

Недостатки

- Крупные ошибки не получают дополнительного усиления.
- Не показывает направление ошибки.
- Как loss негладкая в нуле, поэтому менее удобна для градиентной оптимизации

Для нашего рабочего примера:

$$\begin{aligned}\text{MAE} &= \frac{|4-5| + |6-5| + |10-8| + |16-12|}{4} \\ &= \frac{|-1| + |1| + |2| + |4|}{4} \\ &= \frac{1+1+2+4}{4} \\ &= 2 \text{ млн ₽}\end{aligned}$$

В среднем модель ошибается на **2 млн ₽**.

MSE: средний квадрат ошибки

Mean Squared Error

ФП Метрика

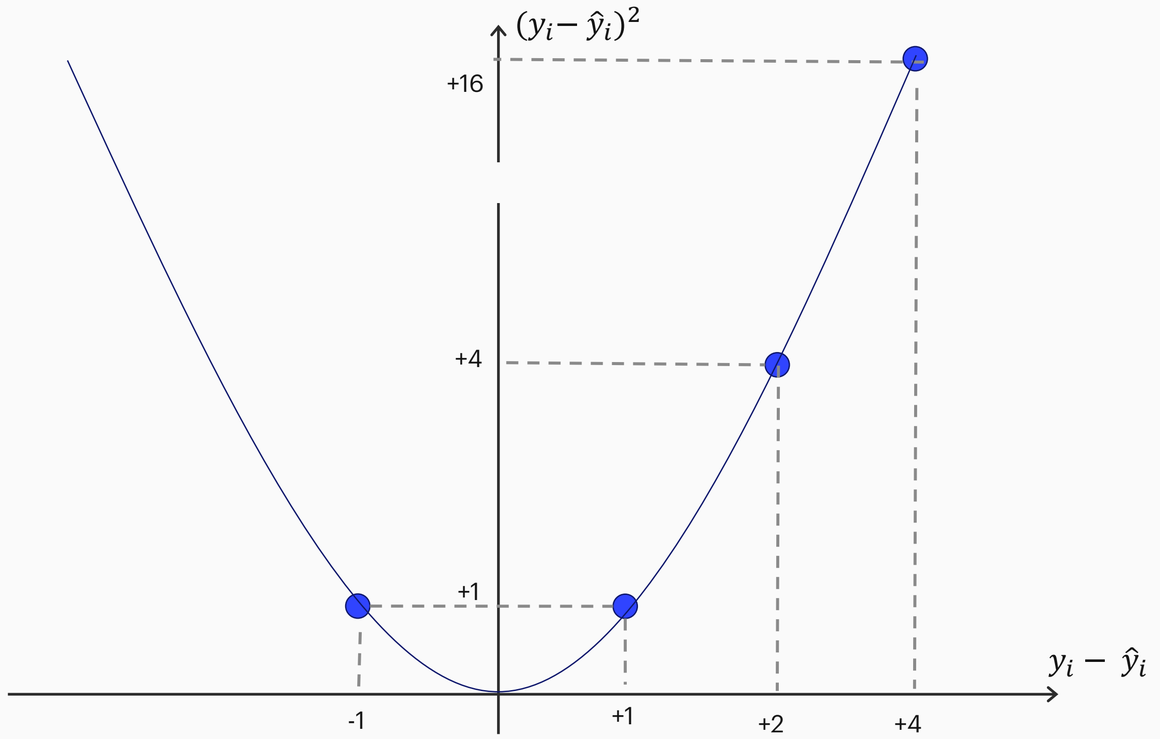
$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Преимущества

- Сильнее штрафует крупные ошибки.
- Гладкая и дифференцируемая, поэтому удобна как loss.

Недостатки

- Чувствительна к выбросам.
- Сложнее интерпретировать, чем MAE.
- Измеряется в квадрате единиц таргета.



Для нашего рабочего примера:

$$\begin{aligned}\text{MSE} &= \frac{(4-5)^2 + (6-5)^2 + (10-8)^2 + (16-12)^2}{4} \\ &= \frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{4} \\ &= \frac{1+1+4+16}{4} \\ &= 5.5\ (\text{млн ₽})^2\end{aligned}$$

MAE и MSE: оптимальные константы

Есть выборка из пяти объектов без признаков: y=[1,2,3,4,100].

Мы можем предсказать всем объектам только одно и то же число c. Какое значение выбрать?

$$L(c) = \frac{1}{n}\sum_{i=1}^{n}(y_i - c)^2$$

MAE и MSE: оптимальные константы

Есть выборка из пяти объектов без признаков: y=[1,2,3,4,100].

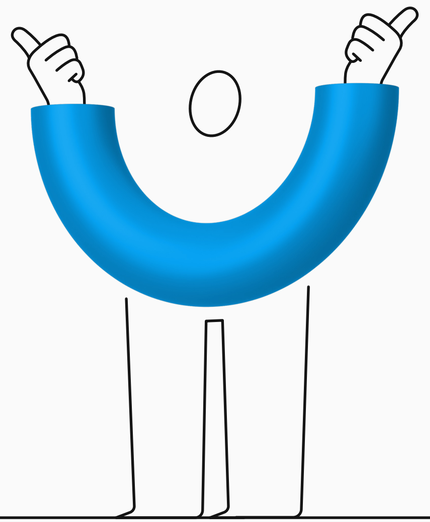
Мы можем предсказать всем объектам только одно и то же число c. Какое значение выбрать?

Решение:

$$L(c) = \frac{1}{n}\sum_{i=1}^{n}(y_i - c)^2$$

$$L'(c) = \frac{2}{n}\sum_{i=1}^{n}(c - y_i) = 2c - \frac{2}{n}\sum_{i=1}^{n} y_i$$

$$L'(c) = 0 \quad \Longrightarrow \quad c = \frac{1}{n}\sum_{i=1}^{n} y_i = \bar{y}$$



MAE и MSE: оптимальные константы

$$c^*_{\text{MSE}} = \arg\min_c \frac{1}{n}\sum_{i=1}^{n}(y_i - c)^2 = \bar{y} = \frac{1+2+3+4+100}{5} = 22$$

$$c^*_{\text{MAE}} = \arg\min_c \frac{1}{n}\sum_{i=1}^{n}|y_i - c| = \text{median}(y) = 3$$

Выбор loss определяет, что учится предсказывать модель: MAE ведёт к медиане, MSE — к среднему.

Huber Loss: MSE для малых ошибок, MAE для больших

ФП

$$\text{Huber}_\delta = \frac{1}{n}\sum_{i=1}^{n}\begin{cases}\frac{1}{2}(y_i-\hat{y}_i)^2, & |y_i-\hat{y}_i|\le\delta,\\ \delta\left(|y_i-\hat{y}_i|-\frac{\delta}{2}\right), & |y_i-\hat{y}_i|>\delta.\end{cases}$$

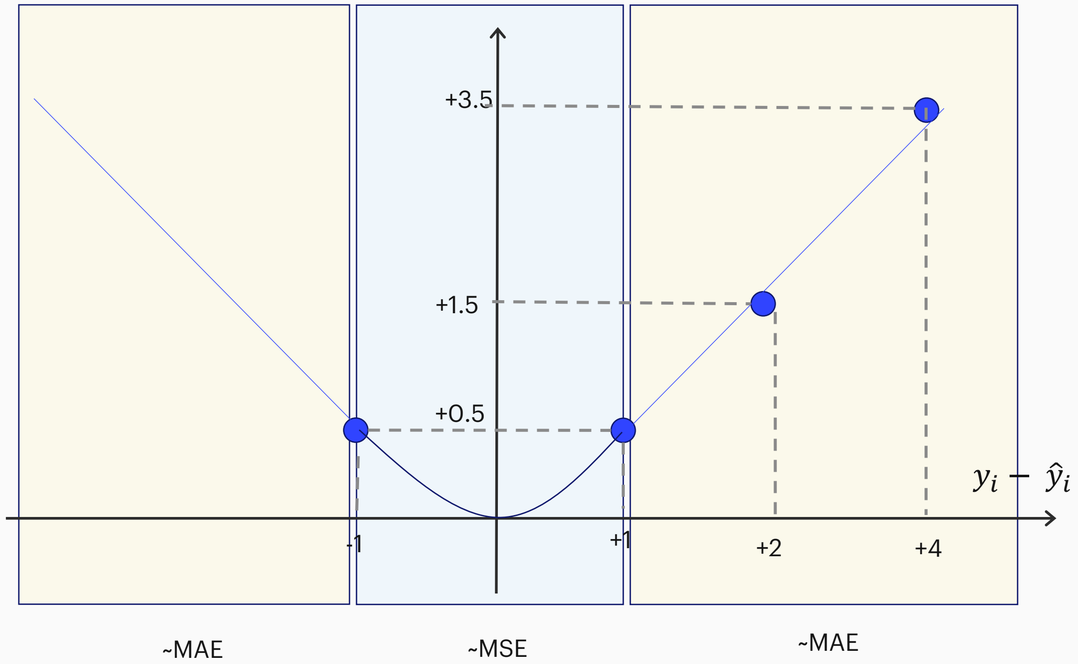
δ — порог переключения: при ошибке до δ штраф квадратичный, после δ — линейный

Преимущества

- Менее чувствительна к выбросам, чем MSE.
- Дифференцируема во всех точках, поэтому удобна для градиентной оптимизации.
- Сочетает свойства MSE и MAE: квадратична для малых ошибок и линейна для больших.

Недостатки

- Нужно подбирать порог δ; он зависит от масштаба таргета.
- Сложнее интерпретировать и объяснять, чем MAE или RMSE.



$$\begin{aligned}\text{Huber}_1 &= \frac{1}{4}\left(\frac{1}{2}(4-5)^2+\frac{1}{2}(6-5)^2+\left(|10-8|-\frac{1}{2}\right)+\left(|16-12|-\frac{1}{2}\right)\right)\\ &= \frac{0.5+0.5+1.5+3.5}{4}\\ &= 1.5\ (\text{млн ₽})^2\end{aligned}$$

При $\delta = 1$ошибки до 1млн ₽ штрафуются квадратично, большие ошибки — линейно

Quantile Loss: разная цена недопрогноза и перепрогноза

ФП

$$\mathrm{QL}_\tau = \frac{1}{n}\sum_{i=1}^{n}\begin{cases}\tau\,(y_i-\hat{y}_i), & y_i \geq \hat{y}_i,\\ (1-\tau)(\hat{y}_i-y_i), & y_i < \hat{y}_i.\end{cases}$$

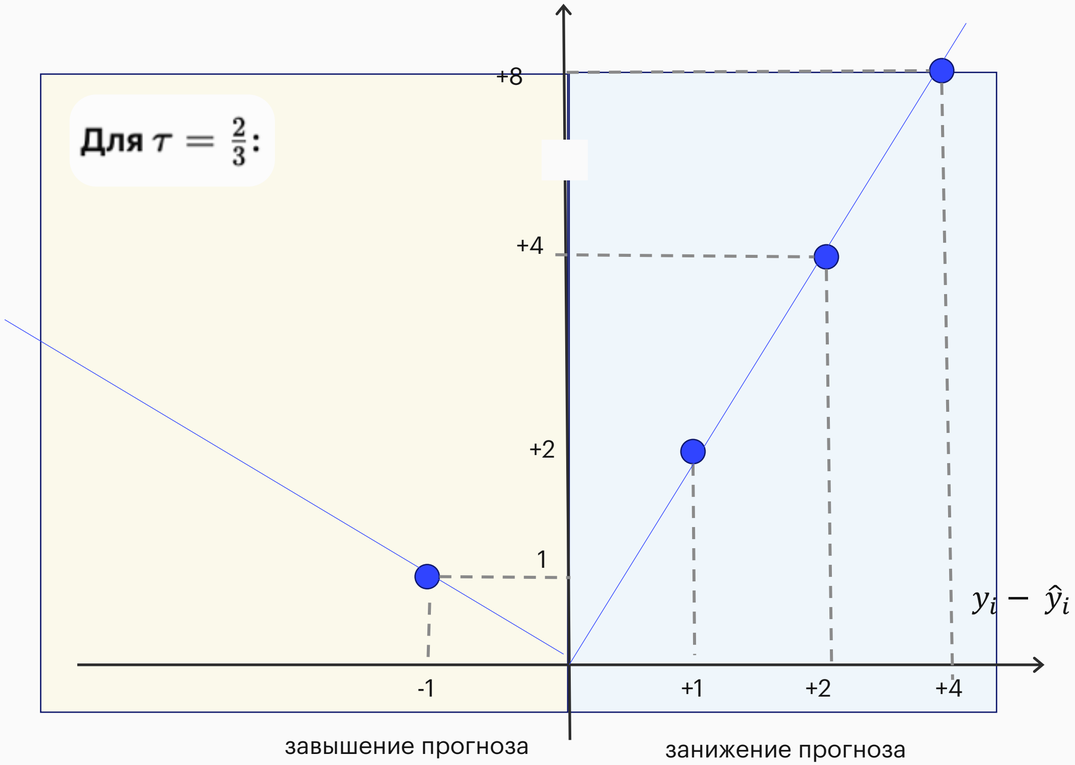
- $\tau = 0.5$ — штрафы симметричны;
- $\tau > 0.5$ — сильнее штрафуем **недопрогноз**;
- $\tau < 0.5$ — сильнее штрафуем **перепрогноз**.

Когда использовать

- Цена недопрогноза и перепрогноза различается.
- Нужен прогноз с запасом вверх или вниз.
- Примеры: спрос, запасы, финансовые риски.

Что важно помнить

- τ задаёт квантиль, который предсказывает модель.
- τ выбирают исходя из бизнес-цены ошибок.



$$\widetilde{\mathrm{QL}}_{\frac{2}{3}} = 3\mathrm{QL}_{\frac{2}{3}} = \frac{1}{4}\left(|4-5| + 2|6-5| + 2|10-8| + 2|16-12|\right)$$

$$= \frac{1+2+4+8}{4} = 3.75 \text{ млн ₽}$$

При $\tau = \frac{2}{3}$ занижение штрафуется в два раза сильнее завышения

* Для удобства визуализации Quantile Loss умножен на 3.
Умножение на положительную константу не меняет точку минимума.

RMSE: корень из среднего квадрата ошибки

Root Mean Squared Error

Метрика

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} = \sqrt{\mathrm{MSE}}$$

Преимущества

- Измеряется в единицах таргета.
- Проще интерпретировать, чем MSE.
- Сильнее учитывает крупные ошибки, чем MAE.

Недостатки

- Чувствительна к выбросам.
- Менее устойчива, чем MAE.
- Не показывает распределение ошибок: одинаковый RMSE могут дать одна крупная или много небольших ошибок.

Для нашего рабочего примера:

$$\begin{aligned}\mathrm{RMSE} &= \sqrt{\mathrm{MSE}} \\ &= \sqrt{\frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{4}} \\ &= \sqrt{\frac{1 + 1 + 4 + 16}{4}} \\ &= \sqrt{5.5} \\ &\approx 2.35 \text{ млн ₽}\end{aligned}$$

Корень из среднего квадрата ошибки равен 2.35 млн ₽.

После извлечения корня возвращаемся из $(\text{млн ₽})^2$ в млн ₽.

R^2: сравнение модели с константным бейзлайном

Коэффициент детерминации

Метрика

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

← сумма квадратов ошибок модели (~MSE).

← сумма квадратов ошибок самой простой модели, которая всегда возвращает среднее значение $\bar{y}$

Как читать:

- **$R^2 = 1$** — идеальное предсказание.
- **$R^2 = 0$** — модель не лучше константного бейзлайна.
- **$R^2 < 0$** — модель хуже бейзлайна.
- **Диапазон:** от $-\infty$ до 1.

Для нашего рабочего примера:

Шаг 1: считаем среднее значение таргета $\bar{y}$

$$\bar{y} = \frac{4 + 6 + 10 + 16}{4} = 9$$

Шаг 2: считаем R^2

$$\begin{aligned} R^2 &= 1 - \frac{(4-5)^2 + (6-5)^2 + (10-8)^2 + (16-12)^2}{(4-9)^2 + (6-9)^2 + (10-9)^2 + (16-9)^2} \\ &= 1 - \frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{(-5)^2 + (-3)^2 + (1)^2 + (7)^2} \\ &= 1 - \frac{1 + 1 + 4 + 16}{25 + 9 + 1 + 49} \\ &= 1 - \frac{22}{84} \\ &\approx 0.74 \end{aligned}$$

$R^2 = 0.74$: модель объясняет качество заметно лучше, чем константный бейзлайн, который всегда предсказывает среднее.

MAPE: средняя абсолютная процентная ошибка

Mean Absolute Percentage Error

Метрика

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Преимущества

- Легко интерпретировать и объяснять бизнесу.
- Не зависит от единиц измерения таргета.
- Удобна для сравнения относительной точности на объектах разного масштаба.

Недостатки

- Не определена при $y_i = 0$.
- Нестабильна при значениях таргета, близких к нулю.
- Может переоценивать ошибки на объектах с маленьким y_i.

Для нашего рабочего примера:

$$\begin{aligned}
\text{MAPE} &= \frac{1}{4}\left(\frac{|4-5|}{4} + \frac{|6-5|}{6} + \frac{|10-8|}{10} + \frac{|16-12|}{16}\right) \cdot 100\% \\
&= \frac{1}{4}\left(\frac{1}{4} + \frac{1}{6} + \frac{2}{10} + \frac{4}{16}\right) \cdot 100\% \\
&= \frac{25\% + 16.7\% + 20\% + 25\%}{4} \\
&\approx 21.7\%
\end{aligned}$$

В среднем прогнозы модели отличаются от истинных значений на 21.7%.

RMSLE, sMAPE, WAPE

Метрика

RMSLE (Root Mean Squared Logarithmic Error) — корень из средней квадратичной ошибки между логарифмами предсказаний и реальных значений.

$$\text{RMSLE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(log(1+\hat{y}_i) - log(1+y_i))^2}$$

sMAPE (Symmetric Mean Absolute Percentage Error) — процентная ошибка MAPE, но **симметричная** по отношению к истинным и предсказанным значениям.

$$\text{sMAPE} = \frac{100\%}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

WAPE (Weighted Absolute Percentage Error) — отношение суммы абсолютных ошибок к сумме абсолютных истинных значений.

$$\text{WAPE} = \frac{\sum|\hat{y}_i - y_i|}{\sum|y_i|} \times 100\%$$

Пример расчета метрик и функционалов потерь



Объекты	$\hat{y}_i$, Прогноз **млн ₽**	y_i, Факт **млн ₽**	$y_i - \hat{y}_i$, Ошибка, **млн ₽.**
Коммуналка	5	4	-1
Студия	5	6	+1
Однокомнатная	8	10	+2
Двухкомнатная	12	16	+4

$$\text{MAE} = 2 \text{ млн ₽}$$

$$\text{MSE} = 5.5 \ (\text{млн ₽})^2$$

$$\text{Huber}_{\delta=1} = 1.5 \ (\text{млн ₽})^2$$

$$L_{\tau=\frac{2}{3}} = 3\,\text{QL}_{\frac{2}{3}} = 3.75 \text{ млн ₽}$$

$$\text{RMSE} \approx 2.35 \text{ млн ₽}$$

$$R^2 \approx 0.74$$

$$\text{MAPE} \approx 21.7\%$$

$$\text{MSLE} \approx 0.0423$$

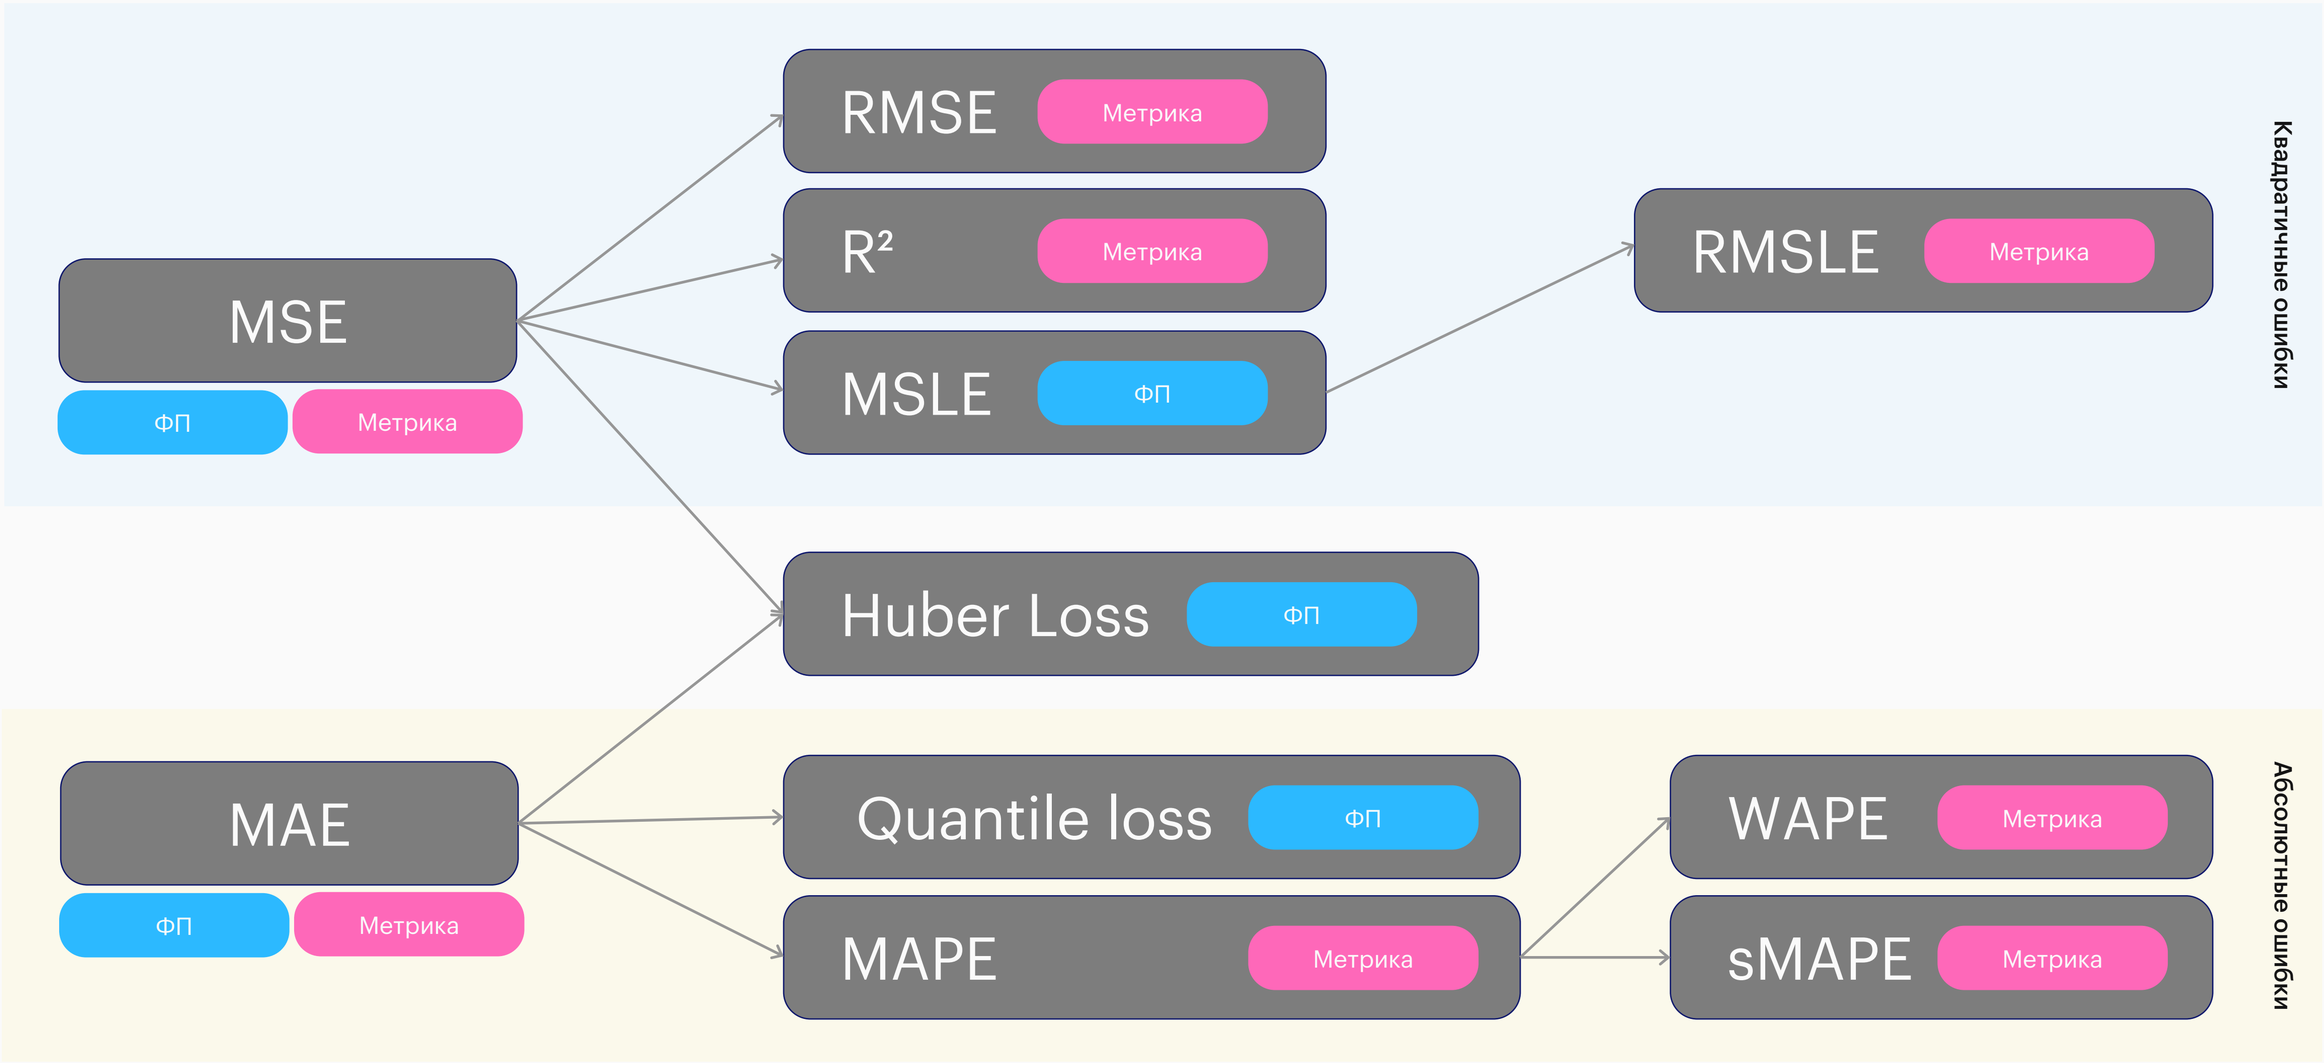
$$\text{RMSLE} \approx 0.206$$

$$\text{sMAPE} \approx 22.8\%$$

$$\text{WAPE} \approx 22.2\%$$

Источник

Карта ФП и метрик регрессии



Применение метрик и ФП регрессии

Самые часто встречающиеся кейсы

Название	Формула	Когда использовать
MAE (Mean Absolute Error)	$MAE = \frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y_i}\rvert$	Когда важна равномерная оценка всех ошибок и устойчивость к выбросам
MSE (Mean Squared Error)	$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2$	Если нужно сильнее штрафовать крупные ошибки
RMSE (Root Mean Squared Error)	$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2}$	Когда важно сохранить масштаб целевой переменной
R² (коэффициент детерминации)	$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$	Когда нужно понять, насколько хорошо модель объясняет поведение целевой переменной
MAPE (Mean Absolute Percentage Error)	$\mathrm{MAPE} = \frac{100\%}{n}\sum_{i=1}^{n}\left\lvert\frac{y_i - \hat{y}_i}{y_i}\right\rvert$	Когда нужно представить бизнесу результат в понятной форме или если в целевой переменной нет значений, близких к нулю

Пример подбора ФП и метрики регрессии

Кейс 1. Прогноз времени доставки из магазина у дома

Предсказываем длительность доставки заказа в минутах для внутреннего планирования курьеров.

- Ошибки в обе стороны одинаково нежелательны.
- Особенно важно избегать крупных промахов.
- Качество нужно оценивать в минутах.

Кейс 2. Прогноз спроса на товары в магазине

Предсказываем спрос на товар на следующий день, чтобы сформировать заказ поставщику.

- Недопрогноз приводит к отсутствию товара и потерянным продажам.
- Перепрогноз приводит к излишкам на складе.
- Недопрогноз обходится примерно в четыре раза дороже.

Кейс 3. Прогноз месячной выручки магазинов

Предсказываем выручку магазинов разных форматов: от небольших точек до гипермаркетов.

- Выручка магазинов различается в десятки раз.
- Важнее относительная ошибка, а не ошибка в рублях.
- Значения таргета положительны, редкие крупные магазины не должны определять всё обучение.

Пример подбора ФП и метрики регрессии

Кейс 1. Прогноз времени доставки из магазина у дома

Предсказываем длительность доставки заказа в минутах для внутреннего планирования курьеров.

- Ошибки в обе стороны одинаково нежелательны.
- Особенно важно избегать крупных промахов.
- Качество нужно оценивать в минутах.

- **ФП: MSE**
  Сильнее штрафует крупные ошибки.
- **Метрика: RMSE**
  Показывает ошибку в минутах.

Кейс 2. Прогноз спроса на товары в магазине

Предсказываем спрос на товар на следующий день, чтобы сформировать заказ поставщику.

- Недопрогноз приводит к отсутствию товара и потерянным продажам.
- Перепрогноз приводит к излишкам на складе.
- Недопрогноз обходится примерно в четыре раза дороже.

- **ФП: Quantile Loss,** $\tau = 0.8$
  Недопрогноз штрафуется в 4 раза сильнее.
- **Метрика: WAPE**
  Показывает суммарную ошибку относительно общего спроса.

Кейс 3. Прогноз месячной выручки магазинов

Предсказываем выручку магазинов разных форматов: от небольших точек до гипермаркетов.

- Выручка магазинов различается в десятки раз.
- Важнее относительная ошибка, а не ошибка в рублях.
- Значения таргета положительны, редкие крупные магазины не должны определять всё обучение.

- **ФП: MSLE**
  Ориентируется на относительные ошибки и снижает влияние масштаба магазина.
- **Метрика: RMSLE**
  Сравнивает качество в логарифмической шкале.
- **Дополнительно: MAPE**
  Даёт понятную бизнесу ошибку в процентах.

Итог. Метрики и функционалы потерь регрессии

Функционал потерь задаёт цель обучения: выбор loss определяет, что именно будет предсказывать модель.

Метрика оценивает качество модели, а одну и ту же функцию иногда используют и как loss, и как метрику.

Универсально лучшего ФП и метрики нет: выбор зависит от масштаба таргета, выбросов и цены разных типов ошибок.

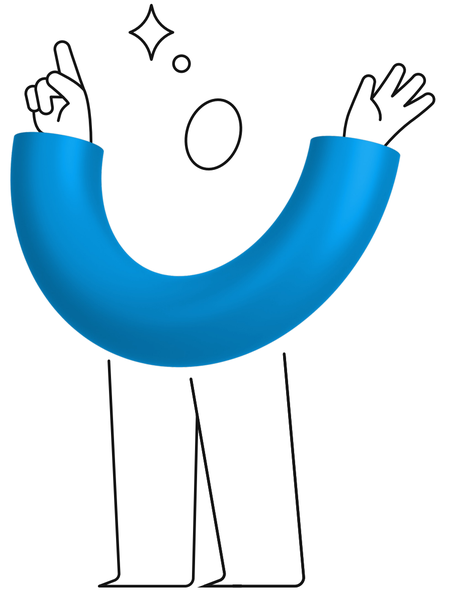
MAE устойчивее к крупным ошибкам, MSE и RMSE сильнее их штрафуют, Huber сочетает оба подхода.

Для относительных и асимметричных ошибок нужны специальные функции: MAPE/RMSLE учитывают масштаб, Quantile Loss — разную цену недопрогноза и перепрогноза.

Итоги

Про курс | Про процесс создания моделей | Функционалы потерь и метрики регрессии

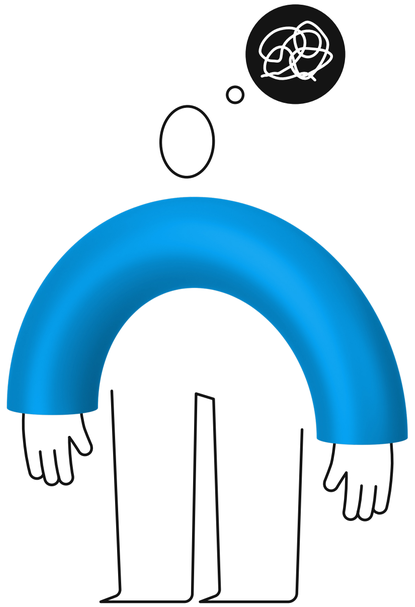
- Курс — про классический ML, без нейросетей.
  При этом многие термины и методы затем будут использоваться в DL.
- Основная цель — понимать и уметь применять алгоритмы: от kNN и линейной регрессии до бустингов, глубокой работы с фичами и временными рядами.
- Это база для практики, собеседований и следующих курсов.



Итоги

Про курс | **Про процесс создания моделей** | Функционалы потерь и метрики регрессии

- → CRISP-DM — база, но в реальной работе pipeline шире: нужно учитывать ограничения в проде, переобучение, поддержку.
- → ML-процесс — итеративный: часто возвращаемся к данным, признакам, задаче.
- → Качество решения = данные + метрики + бизнес-ограничения, не просто «подобрать модель».
- → ML без связи с бизнесом — бесполезен, даже если метрики отличные.



Итоги

Про курс | Про процесс создания моделей | **Функционалы потерь и метрики регрессии**

→ Метрика ≠ Loss.
Метрика нужна для оценки качества, Loss — для обучения. Они не всегда совпадают.

→ Выбор метрики зависит от задачи: нет лучшей метрики для всех случаев.

Ключевые метрики и ФП

→ **MAE** — средняя абсолютная ошибка, устойчива к выбросам.

→ **MSE/RMSE** — сильнее штрафуют большие ошибки, чувствительны к выбросам.

→ **R^2** — показывает, насколько модель лучше простого предсказания среднего.

→ **RMSLE** — полезен, когда важны относительные отклонения.

→ **MAPE/sMAPE/WAPE** — процентные метрики, удобны для бизнеса, но могут вести себя нестабильно при малых значениях.



ЦЕНТРАЛЬНЫЙ УНИВЕРСИТЕТ



Вопросы